



ZADÁNÍ BAKALÁ SKÉ PRÁCE

Název:	Systém pro analýzu proudu dat v reálném áse
Student:	David Viktora
Vedoucí:	Ing. Adam Šenk
Studijní program:	Informatika
Studijní obor:	Informa ní technologie
Katedra:	Katedra po íta ových systém
Platnost zadání:	Do konce letního semestru 2016/17

Pokyny pro vypracování

Sou asným trendem ve zpracování dat, zejména dat ve velkých objemech, je provád t jejich analýzu v reálném áse. Cílem této bakalá ské práce je naimplementovat systém, který by v reálném áse provád l analýzu p ísp vk ze sociální síť Twitter. K analýze bude použit framework Spark. Výsledky analýzy reprezentující p ání uživatel této sociální síť budou persistovány ve vhodném úložišti a p ístupné pomocí RESTového API. Prove te následující kroky:

1. Seznamte se s technologiemi, jež se používají pro zpracování proud dat, zejména s frameworkem Spark.
2. Navrhn te systém, který bude zpracovávat proud dat ze sociální síť Twitter. Výsledky ukládejte a zp ístupn te pomocí RESTového API.
3. Analyzujte metody používané pro zpracování textu. Vyberte n kolik základních, které implementujete do vámi navrženého systému tak, aby bylo možno prokázat jeho funkcionalitu.
4. Systém za použití vhodných technologií naimplementujte.
5. Implementaci otestujte.
6. Zhodno te dosažené výsledky.

Seznam odborné literatury

Dodá vedoucí práce.

L.S.

prof. Ing. Róbert Lórencz, CSc.
vedoucí katedry

prof. Ing. Pavel Tvrdík, CSc.
d kan

V Praze dne 7. prosince 2015

ČESKÉ VYSOKÉ UČENÍ TECHNICKÉ V PRAZE
FAKULTA INFORMAČNÍCH TECHNOLOGIÍ
KATEDRA SOFTWAREVÉHO INŽENÝRSTVÍ



Bakalářská práce

Systém pro analýzu proudu dat v reálném čase

David Viktora

Vedoucí práce: Ing. Adam Šenk

15. května 2016

Poděkování

Rád bych poděkoval především vedoucímu mé závěrečné práce Ing. Adamu Šenkovi za vstřícný přístup a cenné podněty k teoretické i praktické části této práce.

Prohlášení

Prohlašuji, že jsem předloženou práci vypracoval(a) samostatně a že jsem uvedl(a) veškeré použité informační zdroje v souladu s Metodickým pokynem o etické přípravě vysokoškolských závěrečných prací.

Beru na vědomí, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona č. 121/2000 Sb., autorského zákona, ve znění pozdějších předpisů. V souladu s ust. § 46 odst. 6 tohoto zákona tímto uděluji nevýhradní oprávnění (licenci) k užití této mojí práce, a to včetně všech počítačových programů, jež jsou její součástí či přílohou, a veškeré jejich dokumentace (dále souhrnně jen „Dílo“), a to všem osobám, které si přejí Dílo užít. Tyto osoby jsou oprávněny Dílo užít jakýmkoli způsobem, který nesnižuje hodnotu Díla, a za jakýmkoli účelem (včetně užití k výdělečným účelům). Toto oprávnění je časově, teritoriálně i množstevně neomezené. Každá osoba, která využije výše uvedenou licenci, se však zavazuje udělit ke každému dílu, které vznikne (byť jen zčásti) na základě Díla, úpravou Díla, spojením Díla s jiným dílem, zařazením Díla do díla souborného či zpracováním Díla (včetně překladu), licenci alespoň ve výše uvedeném rozsahu a zároveň zpřístupnit zdrojový kód takového díla alespoň srovnatelným způsobem a ve srovnatelném rozsahu, jako je zpřístupněn zdrojový kód Díla.

V Praze dne 15. května 2016

.....

České vysoké učení technické v Praze

Fakulta informačních technologií

© 2016 David Viktora. Všechna práva vyhrazena.

Tato práce vznikla jako školní dílo na Českém vysokém učení technickém v Praze, Fakultě informačních technologií. Práce je chráněna právními předpisy a mezinárodními úmluvami o právu autorském a právech souvisejících s právem autorským. K jejímu užití, s výjimkou bezúplatných zákonných licencí, je nezbytný souhlas autora.

Odkaz na tuto práci

Viktora, David. *Systém pro analýzu proudu dat v reálném čase*. Bakalářská práce. Praha: České vysoké učení technické v Praze, Fakulta informačních technologií, 2016.

Abstrakt

Cílem této práce bylo vytvoření systému pro analýzu proudu dat v reálném čase v kontextu velkých objemů dat. Zpracovávanými daty jsou příspěvky ze sociální sítě Twitter. K samotné analýze byl použit framework Apache Spark, výsledky z něj jsou ukládány do klasické relační databáze a zpřístupněné pomocí REST API. Vytvořený systém umožňuje monitorovat přání uživatelů Twitteru. Díky analýze sentimentu těchto příspěvků by po drobných úpravách mohl být vyvinutý systém použit například při provádění předvolebních průzkumů či analýze oblíbenosti produktů vybrané společnosti.

Klíčová slova Apache Spark, proudové zpracování dat, Big Data, Twitter, sentimentální analýza, REST API

Abstract

The goal of this thesis was to implement a real-time data stream analysis system in the context of Big Data. The data being processed are posts from the Twitter social network. The analysis is implemented using Apache Spark framework, it's results are being saved to relational database and published using REST API. The implemented system allows monitoring of Twitter users' wishes. Thanks to analysing the sentiment of these wishes, after some minor changes, the system could be used for pre-election surveys or to analyse given products popularity.

Keywords Apache Spark, data stream processing, Big Data, Twitter, sentiment analysis, REST API

Obsah

Úvod	1
1 Situace v oblasti zpracovávání dat	3
1.1 Big Data a technologie pro práci s nimi	3
1.2 Apache Spark	7
2 Analýza	13
2.1 Metody pro analýzu textu	13
2.2 Sociální síť Twitter	14
2.3 Požadavky na systém	18
3 Návrh	21
3.1 Analýza tweetů	21
3.2 Struktura databáze	22
3.3 Návrh API	22
4 Implementace	27
4.1 Analýza proudu dat	27
4.2 Databáze	31
4.3 API webserver	35
4.4 Webová aplikace	38
5 Testování	39
5.1 Test API endpointů	39
5.2 Web prezentující výsledky analýzy	40
6 Zhodnocení výsledků	41
6.1 Využití systému	41
6.2 Možná budoucí vylepšení	41

Závěr	43
Literatura	45
A Definice API endpointů	51
B Ukázky webové aplikace	57
C Seznam použitých zkratk	59
D Obsah přiloženého CD	61

Seznam obrázků

1.1	Ukázka fungování MapReduce paradigmatu [10]	5
1.2	Komponenty frameworku Spark[16]	9
1.3	Princip fungování Spark Streaming[18]	10
1.4	Možné zdroje dat a úložiště výsledků pro Spark Streaming[18]	10
2.1	Schéma fungování klasického Twitter REST API[27]	17
2.2	Schéma fungování Twitter Streaming API[27]	17
3.1	Návrh schématu databáze	23
4.1	Diagram nasazení implementovaného systému	28
4.2	Diagram aktivit systému pro analýzu tweetů	31
4.3	Monitoring databáze v Amazon RDS	33
6.1	Zde bude graf vývoje sentimentu	42

Seznam ukázek kódu

3.1	Ukázka požadavku GET	24
3.2	JSON obsahující pole se dvěma uživateli	24
4.1	Vytvoření kontextů a streamu	29
4.2	Vyfiltrování anglických přání	30
4.3	Ukládání statistik do databáze	30
4.4	MySQL Event provádějící agregaci dat	34
4.5	MySQL Event provádějící smazání starých dat	35
4.6	Ukázka použití ORM SQLAlchemy	36
4.7	Ukázka implementace konkrétního API endpointu	37
4.8	Příkaz pro nahrání podadresáře na Heroku	38
5.1	Test endpointu /user/<user_id>	40

Seznam tabulek

Úvod

V současné době generujeme obrovská množství dat - podle některých odhadů to například v roce 2012 mohlo být až 2,5 exabajtů za den[1], od té doby se rychlost jejich přibývání stále zvyšuje. Spolu s nárůstem objemu dat je potřeba vyvinout nové metody umožňující jejich zpracování v přijatelném čase.

Cílem této práce je pomocí frameworku Apache Spark vyvinout systém pro analýzu proudu příspěvků ze sociální sítě Twitter. Tato analýza by měla probíhat v reálném čase a umožňovat monitorovat příspěvky reprezentující přání jejich autorů. Krom obecných statistik bude systém provádět i některé z metod pro analýzu textu. Výsledky této analýzy budou ukládány do databáze a zpřístupněny pomocí REST API. Tento systém by mohl být využit například pro hodnocení úspěšnosti reklamních kampaní nebo obecně při provádění různých průzkumů na sociální síti Twitter.

V první kapitole této práce se budu věnovat především obecným trendům v oblasti zpracování velkých objemů dat a technologiím pro práci s nimi. Ve druhé kapitole seznámím čtenáře s metodami pro analýzu textu a se sociální sítí Twitter. Definuji v ní také požadavky pro implementovaný systém. Jeho bližšímu návrhu včetně například přesné definice REST API endpointů se budu věnovat v kapitole 3. Implementace systému bude popsána ve čtvrté kapitole a jeho testování v kapitole 5. Po té bude následovat zhodnocení dosažených výsledků.

Situace v oblasti zpracovávání dat

Jak bylo zmíněno v úvodu této práce, objem produkováných dat celosvětově výrazně roste. Například nárůst množství dat dostupných na internetu je způsoben jeho neustále větším rozšířením a rostoucí dostupností. V roce 2016 je k němu připojeno již přes 3,3 miliardy obyvatel planety[2], což je téměř polovina celkové populace. Roste také míra využívání internetu. Oproti dřívejšku na internetu trávíme nejen díky chytrým telefonům stále více času a využíváme například sociální sítě, internetové vyhledávání a další online služby. Během toho jsou nám zobrazována personalizovaná data a cílené reklamní nabídky. Také ve firemní i státní sféře výrazně roste stupeň využívání informačních technologií a v návaznosti na to objem produkováných dat. S přibývajícím daty nastávají problémy s jejich zpracováním. Jedním z nich je obecně schopnost zpracovat tak velké objemy dat, druhým je schopnost jejich zpracování v dostatečně krátkém, ideálně reálném čase. Často je přitom potřeba vyřešit oba tyto problémy naráz. Pro popis těchto dat a problémů spojených s jejich zpracováním se používá relativně nový pojem Big Data.

1.1 Big Data a technologie pro práci s nimi

Právě pojem Big Data je často označován za jeden z největších buzzwords¹ současného IT světa. I přes jeho popularitu nejsou přesně vymezené jeho hranice či definované pojmy zabývající se touto oblastí. Obecně můžeme říci, že o Big Datech hovoříme v případech, kdy je potřeba zpracovávat objemy dat v řádech gigabajtů a více. To je velice zjednodušený popis tohoto termínu, přesná definice však neexistuje a na celý problém se dá dívat různými způsoby. Rozšířené je například také tvrzení říkající, že o Big Datech mluvíme zkrátka v

¹Slova nebo fráze, které jsou v dané době populární

těch případech, kdy klasické databázové a softwarové nástroje především kvůli objemu těchto dat selhávají[4].

Přestože jednotná definice neexistuje, ustálilo se několik problémů, kterým je při práci s Big Daty potřeba čelit. Jedná se o takzvaná 3+1V - Volume, Velocity, Variety a později přidaná vlastnost Veracity[5]. Volume popisuje objem zpracovávaných dat, Velocity pak rychlost, jakou data přibývají. Charakteristikou Variety popisujeme různorodost dat a Veracity určuje úplnost a míru důvěryhodnosti dat. Ne vždy se setkáme se všemi těmito problémy naráz, každá z nich ale přidává na složitosti zpracování těchto dat.

Právě kvůli těmto vlastnostem se při práci s velkými objemy dat klasické technologie používané v minulosti stále častěji ukazují jako nedostatečně rychlé nebo obecně neschopné tato data zpracovat. Je proto nutné sáhnout po nových technologiích určených pro práci s nimi. Bez technologií pro Big Data se v dnešní době neobejdou třeba již zmiňované internetové vyhledávače nebo sociální sítě, využití ale nacházejí i v mnoha dalších oblastech. Jejich rozvoj je také předpokladem například pro další rozšíření tzv. Internet of Things[3].

1.1.1 Strukturovaná a nestrukturovaná data

Data obecně často rozdělujeme do dvou kategorií - na data strukturovaná a nestrukturovaná. Strukturovaná data jsou obvykle uložena v klasické relační databázi, nebo obecně utříděna po řádcích a s přesně definovanými sloupci. Ostatní data, která nemají takto pevně danou strukturu, jsou data nestrukturovaná. Ještě donedávna docházelo ke zpracování téměř výhradně dat strukturovaných. Ta nestrukturovaná však často nabízejí obrovský potenciál k jejich využití. Klasickým příkladem nestrukturovaných dat je lidská řeč v psané formě - ta rozhodně obsahuje spoustu informací, ale ve formě kterou je počítačově složité analyzovat. Může se jednat například o články, konverzace nebo příspěvky na sociálních sítích. Právě příspěvkům na sociální síti Twitter se věnuje i tato práce.


Analýzou lidské řeči se zabývá obor zvaný Natural Language Processing či Text Mining, obecně vytěžováním znalostí z dat pak tzv. Data Mining. Často skloňovaným pojmem je také Machine Learning, v češtině strojové učení. Pro všechny tyto obory jsou technologie pro Big Data obrovským přínosem - díky nim je možné získat opravdu cenné informace snáze a rychleji než bylo možné dříve. Například analýzou dat pohybu uživatele po webové stránce a jeho chováním můžeme odhalit nedostatky tohoto webu a jejich odstraněním zvýšit míru konverze. Hovoříme-li v kontextu sociální sítě Twitter, možnosti jsou ještě zajímavější. Na základě příspěvků a vyplněných informací jednotlivých uživatelů můžeme například odhadovat jejich volební preference nebo nabízet velice přesně cílenou reklamu. Konkrétnějším příkladem může být zajímavý projekt ze Stanfordské univerzity usilující o odhad vývoje cen akcií na základě analýzy sentimentu příspěvků z Twitteru[7]. Obecně metodám Text Miningu a především právě analýze sentimentu se věnuji v kapitole 2.1.

Technologie pro Big Data je samozřejmě možné použít i na data strukturovaná, největší využití však nabízejí při zpracování těch nestrukturovaných. Protože nestrukturovaná data přibývají výrazně rychleji[6], a protože je jejich zpracování obvykle výpočetně náročnější, jsou právě technologie pro Big Data vhodnou volbou.

1.1.2 Principy zpracování velkých dat

Jedny z prvních konkrétních technologií pro práci s Big Daty vznikaly na přelomu tisíciletí ve společnosti Google. Právě Google v roce 2004 zveřejnil článek o modelu MapReduce[8], která se stala stavebním kamenem pro většinu dalších technologií pro práci s velkými objemy dat. MapReduce vlastně popisuje dvě nezávislé funkce. První z nich je funkce Map, ve které jsou ze vstupních dat vygenerovány dvojice klíč a hodnota. Poté co je funkce Map dokončena, její výstup je použit jako vstup do funkce Reduce. Ta pak spojí vstupní data podle klíče[9].

Klíčovou vlastností MapReduce modelu je možnost paralelizace Map fáze na počítačovém clusteru. Jeden z počítačů v clusteru například přijme požadavek od uživatele. Tento počítač rozdělí vstupní data ostatním počítačům v clusteru a vyčká na provedení Map fáze těmito počítači. Výsledná data pak sám master spojí v Reduce fázi a navrátí výsledek uživateli. Distribuce co největšího množství operací a výpočtů po počítačovém clusteru je v dnešní době obecně hlavním principem fungování technologií pro zpracování velkých objemů dat. Paradoxně nemusí jít o dražší řešení než nákup jednoho supervýkoného serveru. Clustery pro práci s Big Daty jsou totiž obvykle tvořeny běžně dostupnými a relativně levnými servery.



Obrázek 1.1: Ukázka fungování MapReduce paradigmatu [10]

Především v posledních letech se objevují konkrétní komplexnější nástroje pro práci s velkými daty. Tyto nástroje obvykle obsahují i další technologie,

mimo jiné umožňující například správu počítačového clusteru a zajišťující konzistenci dat. Tyto frameworky principiálně data zpracovávají dvěma různými způsoby - jde o tzv. batchové zpracování nebo o zpracování streamové.

1.1.3 Batchové zpracování Big dat

Batchové neboli dávkové zpracování je vhodné především pro takové úkoly, jejichž výsledky není nutné znát ihned. Data jsou nejprve po určitou dobu shromažďována a až poté je jednorázově spuštěna úloha pro jejich zpracování. Toto zpracování obvykle zabere relativně dlouhý čas. Zmiňovaný MapReduce se využívá právě pro batchové zpracování dat.

Jedním z prvních klíčových frameworků který umožnil další vývoj v oblasti Big dat je jednoznačně open-source framework Hadoop[13]. Protože využívá MapReduce model podporuje právě batchové zpracování dat. Jeho první plná verze vyšla na konci roku 2011, ale byl využíván již přibližně od roku 2006 například ve společnosti Yahoo[11]. Je určen pro použití na počítačových clusterech složených z řádově desítek až stovek běžně dostupných serverů. Hadoop se skládá ze tří hlavních komponent - Hadoop Distributed File System, Hadoop MapReduce a Hadoop YARN. HDFS neboli Hadoop Distributed File System je distribuovaný filesystem zajišťující rozptřeni dat po jednotlivých počítačích v clusteru. Klade důraz na toleranci výpadků částí clusteru. Pro zabránění ztráty dat v případě takového výpadku dochází mimo jiné k jejich replikaci na více strojů. Hadoop MapReduce je konkrétní implementace MapReduce modelu zmiňovaného dříve. Hadoop YARN pak slouží především k řízení zdrojů v clusteru, tedy například rozdělování práce jednotlivým serverům v clusteru. Nevýhodou Hadoopu je fakt, že nepodporuje proudové zpracování dat, ale pouze zpracování batchové.

V současné době jsou k dispozici i další batchově zaměřené frameworky, které často dosahují lepších výsledků než Hadoop a mimo jiné obvykle umožňují vytváření úloh na vyšší úrovni. Díky nim například není nutné přímo vytvářet mapovací a reduce funkci. Nejrozšířenějším je bezesporu Apache Spark[12], kterému se budu podrobněji věnovat v následujících sekcích. Oproti Hadoopu dosahuje především díky cachování a dalším vylepšením často několika-násobně kratší doby zpracování. Krom batchového zpracování umožňuje i práci s proudy dat.

1.1.4 Streamové zpracování

V praxi často potřebujeme velké objemy dat zpracovávat v co nejkratším čase a ideálně na každý nový podnět co nejdříve zareagovat. Batchové zpracování je v takovém případě nevhodné. Řešením je již zmiňované streamové zpracování, nebo také zpracování proudů dat. Vstupem do takového programu není fixní soubor dat, ale neustálý proud dat nových. Kdykoli program obdrží nový datový objekt, zjednodušeně ho začne okamžitě zpracovávat a mezivýsledky

předávat mezi jednotlivými částmi programu nezávisle na dalších vstupech. Technologií umožňujících streamové zpracování velkých objemů dat je několik, ty nejzajímavější jsou ale Apache Spark, Apache Storm a Apache Flink. Každá z těchto technologií funguje na trochu jiném principu a je vhodná pro jiné využití.

- **Apache Flink** je nejnovějším frameworkem, který v relativně velké míře konkuruje Sparku. Stejně jako Spark, podporuje Flink oba způsoby zpracování dat, primárně je ale zaměřený na streamy. Narozdíl od Sparku ale podporuje streamové zpracování v pravém slova smyslu a lze s ním tak dosáhnout výrazně kratší doby zpracování[14]. I právě proto se předpokládá, že v oblasti zpracování proudů dat v budoucnu předstihne Spark[15]. Jeho další výhodou je například možnost využití existujících programů pro Storm či MapReduce. Hlavní nevýhodou je momentálně fakt, že je teprve v počátcích svého vývoje a často se tak uživatel může setkat s bugy či chybějící dokumentací.
- **Apache Storm** jako jediný ze zmiňovaných frameworků nabízí pouze streamové zpracování, i on však poskytuje právě streamové zpracování. Jeho API je oproti Flinku více nízkourovňové a vývoj v něm tak může být pracnější. Obecně ale funguje na podobném principu jako právě Flink.
- **Apache Spark** je rozhodně nejrozšířenější technologií s největší komunitou a pokročilejším stupněm vývoje. Podrobněji se mu věnuji v další sekci. Pro porovnání s dalšími technologiemi ale lze říct, že v oblasti proudového zpracování se hodí především pro ty případy užití, kdy není nutné co nejrychlejší zpracování a řádově několikasekundové zpoždění nehraje roli. Je pak momentálně oproti zbylým technologiím vhodnou volbou díky svojí vyspělosti a jednoduchosti. Pokud je ale nutné opravdu real-time zpracování, je třeba volit mezi Flinkem a Stormem. Ty fungují na podobném principu, nicméně Flink má podle některých uživatelů funkcionality, které ve Stormu chybí[19]. Flink také nabízí vysokoúrovňové API a do budoucna se jeví jako perspektivnější framework.

1.2 Apache Spark

Apache Spark je open-source framework pro distribuované zpracování dat. Vznikl na Kalifornské univerzitě v Berkeley, která ho v roce 2013 věnovala Apache Software Foundation. V rámci této nadace je Spark momentálně jedním z nejaktivněji vyvíjených projektů[20]. Poskytuje API pro jazyky Java, Scala, Python a nově také R. Jak již bylo řečeno, Apache Spark podporuje batchové i proudové zpracování dat.

Primárně je Spark zaměřený na batchové zpracování, ve kterém může Hadoop až několikanásobně překonat svou rychlostí. Toho dosahuje několika vy-

lepšeními - především nepoužívá přímo MapReduce paradigma, které je v některých ohledech příliš svazující, ale vlastní algoritmy založené na podobných principech ale navržené odlišným způsobem. Hadoop například výsledky většiny operací ukládá na disk, kdežto Spark často využívá cachování a operační paměť. Je pak na operačním systému, jestli se rozhodne tato data zapsat na disk[21]. Právě využívání operační paměti pak samozřejmě vede k výraznému zrychlení.

Spark narozdíl od Apache Flink a Apache Storm nenabízí plnohodnotné proudové zpracování, ale takzvané micro-batchové zpracování. Spark nereaguje na každý nový datový objekt samostatně, ale nejdříve data po zadanou dobu strádá a poté je víceméně klasicky batchově zpracuje. Tento proces je pak neustále opakován. Oproti klasickému batchovému zpracování je interval sběru dat obvykle výrazně kratší. Přestože Spark při zpracování proudů dat obvykle nedosahuje takových rychlostí jako právě Flink nebo Storm, i s ním je možné dosáhnout zpracování dat v téměř reálném čase[14].

Stejně jako Hadoop využívá i Spark další technologie pro správu clusteru a distribuované ukládání dat. Jeho velikou výhodou je možnost výběru mezi několika. Pro správu clusteru je možné využít cluster manager integrovaný přímo do Sparku, Hadoop YARN nebo Apache Mesos. Pro distribuované ukládání je pak výběr ještě rozsáhlejší, volit lze mezi již zmiňovaným HDFS, Cassandra, OpenStack Swift, Amazon S3, Kudu nebo MapR-FS. Především při vývoji se pak hodí možnost využití pseudo-distribuovaného režimu, při kterém není žádný z těchto systémů potřeba. Spark totiž při tomto nastavení běží na jediném počítači v režimu, kdy jedno jádro odpovídá jednomu klientskému počítači v clusteru.


1.2.1 Komponenty frameworku

Jak znázorňuje obrázek 1.2, Apache Spark se skládá z několika hlavních komponent. Jedná se především o Spark Core, Spark SQL, Spark Streaming a další menší komponenty. Podrobněji se jim věnuji v následujících sekcích.

1.2.1.1 Spark core

Hlavní komponentou Sparku je Spark Core, který zajišťuje všechny jeho základní funkcionality. jde například o plánování úloh a základní vstupní a výstupní operace. Ostatní komponenty nad ním staví. Základním pojmem je zde tzv. Resilient Distributed Dataset, neboli RDD. RDD je zjednodušeně řečeno téměř libovolná kolekce dat, nad kterou je možné provádět paralelní výpočty. Je navíc zajištěna jejich konzistence - při výpadku některého ze strojů mohou být ztracená data obnovena pomocí informací na těch ostatních.

Kdykoli je na konkrétním RDD vykonána některá z operací umožňujících paralelní zpracování, tzv. transformace (například map, filter nebo reduce), driver neboli počítač řídící ostatní počítače naplánuje její zpracování na všech



Obrázek 1.2: Komponenty frameworku Spark[16]

počítačích v clusteru. Ty poté vytvoří nová RDD s výsledky. Operace na RDD jsou ale "lazy", což znamená, že se neprovádějí dokud na RDD neaplikujeme nějakou akci. Akce je opakem transformace a jejím výsledkem není vytvoření nového RDD. Příkladem akce je vypsání obsahu RDD na standartní výstup.

1.2.1.2 Spark SQL

Další důležitou komponentou je Spark SQL, dříve nazývaný jako Apache Shark. Ten umožňuje práci s především strukturovanými daty. Zavádí také novou strukturu zvanou Data Frame (DF). Stejně jako RDD, je i Data Frame distribuovaný po clusteru. Jeho struktura je ale narozdíl od RDD pevně daná - konceptuálně odpovídá klasické tabulce v relační databázi. Vnitřně v něm dochází k optimalizacím urychlujícím operaci s ním.

Hlavní předností Spark SQL je možnost používat klasické SQL nebo HiveQL² dotazy, jejichž výsledky jsou uloženy právě jako Data Frame. Například komunikace s klasickou relační databází je možná pomocí JDBC/ODBC³.

1.2.1.3 Spark Streaming

Zjednodušený princip fungování komponenty je popsán na obrázku 1.3. Jak již bylo řečeno, Spark neumožňuje streamové zpracování v pravém slova smyslu, ale pracuje na principu tzv. micro-batchového zpracování. To způsobuje mírné

²HiveQL je jazyk používaný v Apache Hive. Je podobný jazyku SQL, některé funkcionality však postrádá a jiné má navíc.

³Jednotné API pro přístup a práci s relačními databázemi.

zpoždění výsledků, ty ale nepotřebujeme znát vždy opravdu ihned. Velikou výhodou je fakt, že programy určené pro streamové zpracování se ve Sparku téměř neliší od těch určených k jednorázovému spuštění.



Obrázek 1.3: Princip fungování Spark Streaming[18]

Jak ukazuje obrázek 1.4, jako zdroj dat pro Spark Streaming může posloužit například Kafka, Flume, HDFS, Amazon S3 nebo Kinesis. Přímo lze také využívat data z Twitteru bez nutnosti používání dalších knihoven. Právě Twitter poslouží jako zdroj dat pro systém na který se zaměřuje tato práce.



Obrázek 1.4: Možné zdroje dat a úložiště výsledků pro Spark Streaming[18]

I Spark Streaming zavádí novou strukturu. Nazývá se Discretized Stream neboli DStream. Jde o nekonečnou posloupnost nových dat reprezentovaných jednotlivými RDD. Při psaní konkrétních programů pak stačí nastavit délku intervalu, ve kterém se má opakovaně spouštět daná úloha. DStream pak v každém intervalu dané délky vrátí právě jedno RDD, které je již možné klasicky zpracovat.

1.2.1.4 MLlib

MLlib je framework určený pro strojové učení. Právě díky vlastnostem Sparku (především díky využívání operační paměti a distribuci výpočtů) poskytuje často lepší výsledky než klasické technologie pro machine learning[17]. Výho-

dou tohoto frameworku je to, že v něm jsou již naimplementovány nejpoužívanější algoritmy. Není tak nutná jejich reimplementace uživatelem.

1.2.1.5 Graphx

GraphX je ve Sparku relativně novým modulem, který je určený obecně pro práci s grafy a paralelními grafovými výpočty. Grafové výpočty získávají stále více pozornosti, jednoduchým příkladem je algoritmus PageRank, který stál u zrodu moderního vyhledávání v Google[22].

Analýza

V této kapitole se nejdříve v sekci 2.1 věnuji dostupným metodám pro analýzu textu, především pak metodě zvané sentimentální analýza. V sekci 2.2 se zabývám sociální sítí Twitter a jí poskytovaným rozhraním, které bude v rámci této práce využito. Poslední sekce 2.3 je pak zaměřena na definování požadavků na implementovaný systém.

2.1 Metody pro analýzu textu

Získáváním informací z běžného textu se zabývá obor zvaný Text Mining. Jde o obor na pomezí strojového učení a klasického data miningu který umožňuje získávání strukturovaných dat z běžného textu, tedy dat nestrukturovaných. K tomu jsou obvykle použity techniky právě ze zmiňovaných disciplín. Několik základních metod pro dolování dat z textu popisují v následujících sekcích.

Protože příspěvky ze sociální sítě Twitter, jejichž analýze se tato práce věnuje, jsou relativně krátké a obsahově specifické, v rámci této práce bude použita pouze metoda zvaná Analýza sentimentu. Té se věnuji nejprve obecně v sekci 2.1.4. Její použití v kontextu této práce pak podrobněji popisují v kapitole 4.1.

2.1.1 Text Categorization

Text Categorization, někdy také Text Classification je metodou umožňující rozdělení analyzovaných dokumentů do předem daných skupin, jako například sport, politika a věda. Kategorizace je založena na četnosti jednotlivých slov v analyzovaném textu - pokud například text často obsahuje slova spadající do kategorie sport, bude i celý text do této kategorie zařazen. Rozdělení slov do jednotlivých kategorií je dosaženo buďto manuálně nebo právě pomocí technik strojového učení. Jeden dokument může být obvykle zařazen do více kategorií.

2.1.2 Text Clustering

Text Clustering neboli shlukování textů je metoda umožňující seskupování podobných dokumentů. Místo do předem daných kategorií jsou tyto dokumenty přiřazovány na základě jejich podobnosti do dynamicky vytvářených skupin. I zde je rozdělení dosaženo pomocí četnosti jednotlivých použitých slov. Každý dokument je obvykle přiřazen do jediné kategorie.

2.1.3 Document Summarization

Vytvářením krátkých shrnujících textů se zabývá metoda zvaná Document Summarization. Jednodušší varianta této metody funguje na principu výběru klíčových vět dokumentu a jejich správného seřazení. Ta složitější pak spočívá v opravdu podrobném rozboru dokumentu, především pak v jeho syntaktické analýze. Na základě té pak dochází k vytvoření kompletně nového textu shrnujícího text původní. Praktické provedení takové analýzy a následné vytvoření shrnutí je nicméně velice složité a nejsme tak prozatím obvykle schopni dosáhnout tak dobrých výsledků jako pomocí prvně zmíněné varianty[31].

2.1.4 Sentiment Analysis

Sentiment analysis, v češtině analýza sentimentu, je metodou pro určování celkové nálady či positivity daného textu. Výsledkem této analýzy tedy nejsou žádné faktické informace, ale hodnota určující subjektivní názor autora textu na dané téma.

Jednodušší verze algoritmů pro analýzu sentimentu fungují na podobném principu jako předchozí metody. Text je rozdělen na jednotlivá slova, z nichž každému je přiděleno negativní, neutrální nebo pozitivní hodnocení. Tato hodnocení jsou posléze zprůměrována. Tímto způsobem však dochází ke ztrátě podstatných informací - dochází k zanedbání pořadí slov a především nejsou zohledňovány například negace, které mohou změnit celý význam věty. Příkladem může být následující věta:

This movie was actually neither that funny, nor super witty.

V rámci této práce bude použita knihovna Stanford NLP[32], která mimo jiné obsahuje právě funkce pro analýzu sentimentu. Ty jsou již výrazně propracovanější a výše zmiňovanou větu ohodnotí jako negativní. Podrobněji se použité knihovně věnuji v sekci 4.1.1.1.

2.2 Sociální síť Twitter

Twitter je v současnosti jednou z nejpoužívanějších sociálních sítí. Poskytuje svým uživatelům mikrobloginovací funkcionality - umožňuje zveřejňovat

140 znaků dlouhé zprávy (tzv. tweety) a číst zprávy publikované ostatními. Účet na něm má odhadem 1,3 milardy uživatelů, denně se jich pak na Twitter přihlásí asi 100 milionů[23]. Tito uživatelé pak každý den zveřejní 500 milionů tweetů, což odpovídá přibližně 6000 tweetů každou sekundu[24].

2.2.1 Vysvětlení pojmů

Pro bližší pochopení fungování sociální sítě Twitter a analýzy příspěvků z ní pro účely této práce je potřeba vysvětlit několik základních termínů:

2.2.1.1 Tweet

Tweet je tím nejdůležitějším pojmem na Twitteru. Jak již bylo řečeno, jedná se o zprávu o maximální délce 140 znaků. Důvody pro toto omezení jsou v dnešní době víceméně historické - Twitter byl totiž už od svých počátků zamýšlen pro použití na mobilních telefonech. Protože klasické textové zprávy posílané právě pomocí mobilních telefonů jsou omezeny na 160 znaků, bylo toto omezení při vzniku Twitteru bráno v potaz. Samotný 140 znaků dlouhý tweet by zabral většinu délky SMS zprávy, zbylých 20 znaků bylo vyhrazeno pro jméno autora zprávy[25]. Nicméně i dnes má toto omezení smysl - nutí uživatele zprávy zkracovat a zmiňovat to nejdůležitější.

Všechny tweety zveřejněné uživatelem jsou standartně viditelné pro všechny. Uživatel však má možnost nastavit si vyšší úroveň soukromí. Přímo na hlavní stránce se uživateli zobrazují příspěvky těch uživatelů, jejichž je tzv. follower.

2.2.2 Follower

Followerem neboli "sledujícím" jiného uživatele se člověk stane jednoduše kliknutím na tlačítko Follow na profilu vybraného uživatele. To způsobí právě zobrazování zpráv sledovaného uživatele na hlavní stránce Twitteru. Každý uživatel si může zobrazit seznam uživatelů kteří ho sledují.

2.2.2.1 Retweet

Často používanou funkcionalitou Twitteru je možnost přeposlat zprávy někoho jiného neboli vytvořit tzv. retweet. Taková zpráva pak začíná písmeny RT označujícími právě retweet, za nimi pak následuje jméno původního autora zprávy.

2.2.2.2 Hashtag

Hashtag je řetězec začínající znakem "#". Hashtagy vkládají samotní uživatelé do jimi publikovaných tweetů. Na základě použitého hashtagu je pak možno vyhledat i ostatní zprávy, které ho obsahují. Příkladem může být hashtag #rio2016 používaný pro tweety týkající se nadcházejících olympijských her

2. ANALÝZA

v brazilském Rio de Janeiru. Dostupné hashtagy však nejsou nijak omezeny, použít může být libovolný řetězec.

2.2.2.3 Mention

Stejně jako může tweet obsahovat hashtag, může v něm být zmíněný jiný uživatel Twitteru. Toto zmínění je v originále označováno jako tzv. Mention. Pro zmínění jiného uživatele je použit znak zavináče následovaný uživatelským jménem.

2.2.3 Twitter Streaming API

Twitter poskytuje dvě rozhraní pro přístup k jeho datům. Jde o klasické REST API s mnoha různými endpointy⁴ a dále o několik streamových endpointů. Tato práce využívá streamové API, konkrétně stream poskytující vzorek veřejně publikovaných tweetů[26]. Počet tweetů které toto API poskytuje není přesně daný, nicméně experimentálně bylo zjištěno, že jde o přibližně 60 až 80 příspěvků za sekundu. To odpovídá asi 1% publikovaných tweetů.

Získat lze samozřejmě i přístup ke všem veřejně publikovaným příspěvkům. Nejde však již o volně dostupná API a přístup k nim je placený. Tuto službu nabízí portál Gnip.com[29]. Pro tuto práci je použito pouze veřejně dostupné API.

Pro různé případy užití se hodí využít různá rozhraní. Klasický případ využití RESTového API ukazuje obrázek 2.1 - uživatel navštíví webovou stránkou a chce zobrazit například údaje o konkrétním uživateli. Server tento požadavek přijme a sám odešle požadavek na API poskytované Twitterem. Ten mu odpoví, server data zpracuje a vrátí je původnímu uživateli.

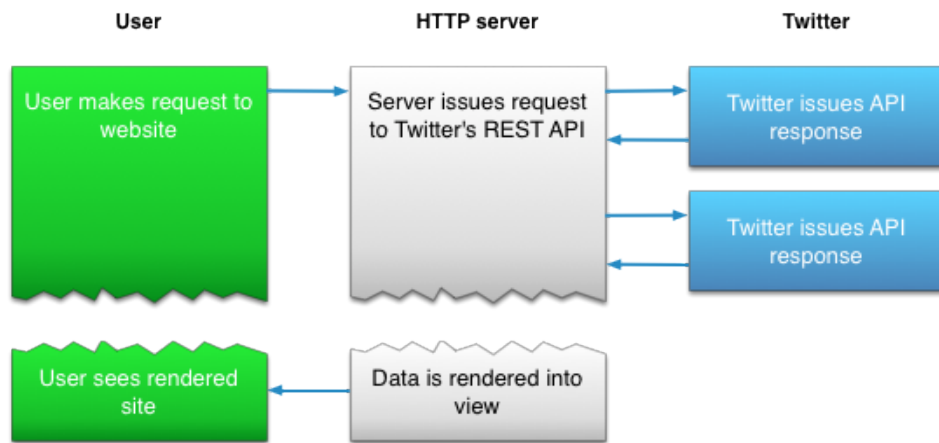
V některých případech je ale vhodnější využít právě streaming API. Pokud nepotřebujeme okamžitě reagovat na jednotlivé požadavky uživatelů ale naopak chceme data zpracovávat kontinuálně, je streaming API jasnou volbou. Mimo jiné díky němu dosáhneme nižšího zatížení serveru, protože není nutné neustálne navazovat nová spojení. Tento princip je popsán na obrázku 2.2.

2.2.3.1 Twitter4j

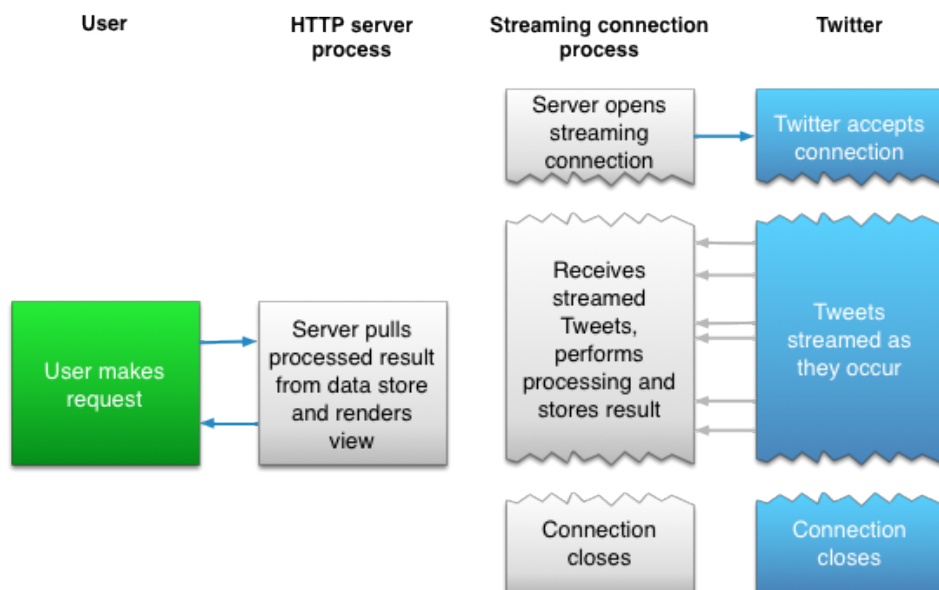
Popisovat konkrétní parametry použitého streaming API nemá v kontextu této práce smysl. Spark streaming má totiž v sobě Twitter Streaming API zaintegrované jako jeden z možných zdrojů dat a veškerou práci s API tak řeší za uživatele. Je pouze třeba nastavit přístupové údaje k API, které je možné získat vytvořením vývojářského Twitter účtu.

Spark navíc využívá java knihovnu Twitter4j[28], která usnadňuje práci s Twitter API. Díky tomu jsou jednotlivá RDD tvořena již přímo objekty reprezentující jednotlivé tweety. Pomocí metod těchto objektů je pak možné o

⁴Konkrétní adresa umožňující přístup k datům.



Obrázek 2.1: Schéma fungování klasického Twitter REST API[27]



Obrázek 2.2: Schéma fungování Twitter Streaming API[27]

každém tweetu snadno získat všechny dostupné informace, včetně například údajů o autorovi tweetu.

2.3 Požadavky na systém

Jak podrobněji popisují v kapitole 3, výsledný systém jehož vytvoření je cílem této práce se bude skládat ze tří klíčových částí - systému pro analýzu textu, databáze a webserveru zpřístupňujícího data pomocí RESTového API. Pojmu REST API se podrobněji věnuji v sekci 3.3.

První zmiňovaná část, systém pro analýzu textu, bude využívat framework Apache Spark. Jako zdroj dat bude použita sociální síť Twitter poskytující vzorek příspěvků z ní, tzv. tweetů, pomocí veřejného API. Tomu se podrobněji věnuji v kapitole 2.2.3. Z těchto příspěvků budou vyfiltrovány ty, které reprezentují přání jejich autorů. Kromě měření běžných statistik bude systém provádět analýzu sentimentu těchto přání. Tato analýza bude probíhat v reálném čase, respektive se zpožděním v řádu maximálně několika desítek sekund. Výsledky analýzy z této části budou persistovány ve vhodné relační databázi. Na ní bude napojen webový server zpřístupňující data pomocí RESTful API.

2.3.1 Funkční požadavky

2.3.1.1 Systém pro analýzu textu

Samotný systém pro analýzu textu musí splňovat následující požadavky:

- Získání a ukládání veškerých dat, jejichž zpřístupnění pomocí RESTového API je požadováno a jež nejsou získávána jiným způsobem

2.3.1.2 Databáze

Databáze bude poskytovat následující funkcionality:

- Agregace statistických dat dle času - u dat u kterých je to možné bude docházet k jejich seskupování po větších intervalech. Tím dojde ke snížení náročnosti dotazů na tato data.
- Promazávání starých a již zagregovaných dat

2.3.1.3 RESTful API

RESTful API bude poskytovat následující data:

- Jednotlivá přání a základní informace o nich, včetně jejich sentimentu a informací o jejich autorovi
- Seznam uživatelů zmíněných v konkrétním přání
- Seznam hashtagů použitých v konkrétním přání
- Informace o uživateli, kteří jsou autory některého přání nebo byli v některém zmíněni

- Seznam přání publikovaných daným uživatelem
- Seznam přání v nichž byl daný uživatel zmíněn
- Seznam přání obsahujících daný hashtag
- Statistiky nejpoužívanějších hashtagů
- Statistiky nejvíce zmiňovaných uživatelů
- Statistiky o počtech již analyzovaných tweetů, anglických tweetů a z nich vyfiltrovaných přání v daném časovém intervalu
- Statistika o průměrném sentimentu v daném intervalu

Pro data pro která je to vhodné bude API umožňovat:

- Omezení počtu vrácených výsledků
- Nastavení časového intervalu
- Poskytnutí pouze některých hodnot, například pouze statistik počtu anglických tweetů namísto veškerých statistických údajů

2.3.2 Nefunkční požadavky

2.3.2.1 Kvalitativní

- **Rychlost** - analýza textu bude probíhat v reálném čase, respektive se zpožděním v řádu maximálně několika desítek sekund
- **Škálovatelnost** - systém pro analýzu textu bude při nasazení na dostatečně výkonném počítačovém clusteru připraven pro zpracování tisíců příspěvků za sekundu

2.3.2.2 Omezující

- **Framework pro analýzu** - k analýze příspěvků z Twitteru bude použit framework Apeche Spark a jeho komponenta Spark Streaming
- **Zpřístupnění dat** - data budou zpřístupněna pomocí RESTful API. To bude odpovídat běžným praktikám používaným právě při návrhu RESTových rozhraní

Návrh

V této kapitole se věnuji návrhu jednotlivých komponent implementovaného systému. Jak již bylo nastíněno v definici požadavků, bude se tento systém skládat z několika hlavních částí:

- **Systém pro analýzu tweetů** využívající framework Spark bude sloužit k analýze příspěvků ze sociální sítě Twitter. Po vyfiltrování tweetů reprezentujících přání jejich autorů provede analýzu sentimentu těchto tweetů. Výsledky analýzy budou společně s obecnými údaji o zpracovávaných textech uloženy do databáze.
- **Databáze** bude uchovávat veškeré potřebné údaje o analyzovaných příspěvcích. Krom toho bude v databázi docházet k agregaci dat pro dosažení snížené zátáže.
- **Webserver poskytující REST API** bude zpřístupňovat veškeré údaje, jejichž dostupnost je vyžadována ve funkčních požadavcích.
- **Webová aplikace** sice není součástí zadání této práce, bude nicméně implementována z důvodů prezentace výsledků a testování API.

Jednotlivé části podrobněji popisují v následujících sekcích.

3.1 Analýza tweetů

Program pro analýzu tweetů bude klíčovou částí celého systému. Bude v něm totiž docházet ke zpracování veškerých dat. Hlavními cíli této komponenty jsou:

- **Vyfiltrování anglických přání.** Příspěvky publikované na Twitteru jsou napsány v různých jazycích, tento systém bude však provádět analýzu pouze těch anglických. Je proto nejprve nutné anglické příspěvky vyfiltrovat. Samotné vyfiltrování příspěvků reprezentujících přání jejich

autorů pak bude provedeno jednoduše nalezením tweetů obsahujících slova *wish*, *hope* nebo *pray*.

- **Ukládání přání a souvisejících údajů.** Veškerá vyfiltrovaná přání a dále údaje o jeho autorovi, zmíněných uživateli a obsažených hashtagích budou ukládány do databáze.
- **Provedení analýzy sentimentu jednotlivých přání.** U veškerých vyfiltrováních přání bude provede analýza sentimentu, jejíž výsledky budou taktéž uloženy do databáze.
- **Ukládání obecných statistik.** Během zpracování budou ukládány také obecné statistiky o počtech zpracovaných příspěvků a průměrném sentimentu v daném časovém intervalu.

Celý tento proces se pak bude neustále opakovat každých 40 vteřin. Data budou nejprve po tuto dobu strádána, poté dojde k jejich zpracování. V případě zpoždění zpracování nebude docházet ke ztrátě dat.

3.2 Struktura databáze

Databáze uchovávající výsledky analýzy dat musí pojmout všechna data, jejichž zpřístupnění je dle funkčních požadavků vyžadováno. Konkrétní strukturu databáze ukazuje obrázek 3.1.

V horní části obrázku jsou umístěny tabulky uchovávající obecné statistiky o zpracovaných datech. Z nich pouze do první tabulky *stats_general_40s* bude přímo vkládat data systém pro analýzu textu. Zbylé dvě tabulky budou obsahovat agregovaná data, jak vysvětluji v sekci 4.2.3.

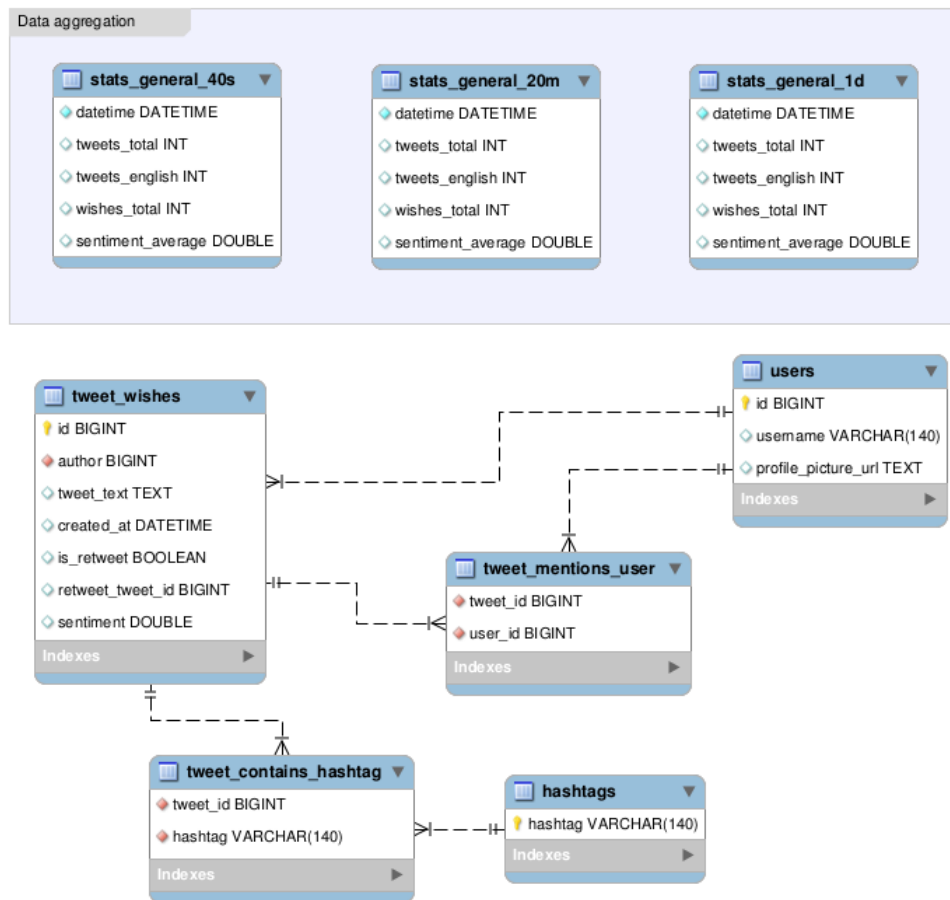
Krom obecných statistik budou ukládána veškerá analyzovaná přání včetně výsledku jejich sentimentální analýzy. V tabulce *users* pak budou uloženy základní údaje o všech uživateli, kteří jsou autory některého z analyzovaných přání nebo jsou v něm zmíněni. Vztah vyjadřující zmínění uživatele v tweetu bude vyjádřen tabulkou *tweet_mentions_user*.

Stejně tak jsou tabulce *hashtags* uloženy všechny hashtagy použité v některém z přání. Použití hashtagu v přání vyjadřuje tabulka *tweet_contains_hashtag*.

3.3 Návrh API

3.3.1 REST architektura

Jedním z požadavků pro API poskytující výsledky analýzy dat je využití REST neboli Representational State Transfer architektury. Tato architektura rozhraní byla představena v roce 2000 Royem Fieldingem, spoluautorem protokolu HTTP[33]. Proto není překvapením že REST pro přenos dat využívá právě tento protokol. Jedná se o bezstavovou architekturu, která poskytuje



Obrázek 3.1: Návrh schématu databáze

jednoduchý a především jednotný přístup ke zdrojům. Za zdroj pak považujeme samotná data či stavy aplikace.

Každý zdroj má svoji vlastní URI⁵. REST definuje čtyři základní metody pro přístup k těmto zdrojům. Tyto základní metody protokolu HTTP jsou označovány jako CRUD - umožňují totiž vytvoření dat (Create), jejich získání (Retrieve), aktualizování (Update) a smazání (Delete):

- **GET**

Get je tou nejzákladnější metodou, která slouží k získání zdroje. Při používání webového prohlížeče se s ním setkáváme neustále - jedná se totiž o metodu sloužící jako klasický požadavek na webovou stránku. Případné parametry jsou přidány přímo do URI. Například pro získání informací o uživateli Jan můžeme použít požadavek 3.1.

⁵Uniform Resource Identifier je řetězec jednoznačně určující zdroj informací

3. NÁVRH

```
1 GET /api/user/jan
2 Host: www.my-web.com
```

Zdrojový kód 3.1: Ukázka požadavku GET

- **POST**

Post je metoda sloužící pro vytváření dat nových, která se používá například u klasických webových formulářů. Parametry s údaji pro nová data nejsou součástí URI ale přímo HTTP dotazu.

- **DELETE**

Metoda Delete slouží ke smazání konkrétního zdroje definovaného pomocí URI. HTTP požadavek pro smazání uživatele Jan by se nelišil od výše uvedeného příkladu požadavku GET, pouze by bylo nutné použít metodu DELETE.

- **PUT**

Put je metodou sloužící k aktualizaci zdroje. Jde jistým způsobem o kombinaci GET a POST - používá přímo URI již existujícího zdroje jako GET, zároveň ale jako POST v těle HTTP požadavku odesílá nová data sloužící k aktualizaci tohoto zdroje.

3.3.2 JSON

Jedním z nejčastěji používaných formátů pro přenos dat v kombinaci s RESTovým API je JSON, neboli JavaScript Object Notation. Použit bude i v rámci této práce. Skládá se z dvojic klíčů a hodnot a jeho hlavními výhodami jsou jednoduchá struktura, přehlednost a čitelnost[34].

Většina programovacích jazyků navíc obsahuje knihovny a funkce, které umožňují jednoduché zpracování tohoto formátu. Například v jazyce Python formát JSON v podstatě odpovídá klasickému slovníku. Ukázka 3.2 zobrazuje zápis objektu obsahujícího pole se dvěma uživateli.

```
1 {
2   "users": [{
3     "name": "Jan Novak",
4     "age": 24,
5     "address": {
6       "city": "Praha 7",
7       "street": "Dlouha",
8       "street_number": "451"
9     }
10  }, {
```

```

11     "name": "Karel Spacek",
12     "age": 46,
13     "address": {
14         "city": "Praha 4",
15         "street": "Siroka",
16         "street_number": "841"
17     }
18 }
19 }

```

Zdrojový kód 3.2: JSON obsahující pole se dvěma uživateli

3.3.3 API endpointy

Kromě použití architektury REST je také nutné splnit všechny funkční požadavky definované v sekci 2.3. Jelikož API data pouze zpřístupňuje ale nikterak je neupravuje, veškeré API endpointy budou využívat pouze výše popsanou metodu GET. Podrobný popis implementovaných API endpointů je možné najít v příloze A. Zjednodušený popis je pak dostupný přímo zde:

/wish/
GET Seznam přání

Bez použití následujících parametrů vrátí všechna přání za posledních 10 minut. Při použití *count* jsou ignorovány parametry *from* a *to*.

from	timestamp	od včetně
to	timestamp	do vyjímaje
count	integer	omezení počtu vrácených přání

/wish/{wish_id}
GET Konkrétní přání

Vrací stejné údaje jako */wish/*, ale pouze pro konkrétní přání s daným *wish_id*.

/wish/{wish_id}/mentions
GET Uživatelé zmíněný v přání

Vrací seznam uživatelů zmíněných v přání s daným *wish_id*.

/wish/{wish_id}/hashtags
GET Hashtagy použité v přání

Vrací seznam hashtagů použitých v přání s daným *wish_id*.

3. NÁVRH

/user/
GET Seznam uživatelů

Vrací seznam všech uživatelů, tedy autorů přání nebo uživatelů zmíněných v některém z nich.

/user/{user_id}
GET Konkrétní uživatel

Vrací údaje o konkrétním uživateli s daným *user_id*.

/user/{user_id}/wishes
GET Přání daného uživatele

Vrací seznam přání uživatele s daným *user_id*.

/user/{user_id}/mentioned_in
GET Zmínění daného uživatele

Vrací seznam přání, ve kterých byl uživatel s daným *user_id* zmíněn.

/hashtag/{hashtag}/wishes
GET Přání obsahující daný hashtag

Vrací seznam přání, ve kterých byl použit daný *hashtag*.

/stats/mentions
GET Seznam zmiňovaných uživatelů

Bez použití následujících parametrů vrátí seznam všech zmíněných uživatelů v posledních 10 minutách společně s počtem jejich zmínění.

Výsledky jsou řazeny sestupně dle počtu zmínění v daném intervalu.

from	timestamp	od včetně
to	timestamp	do vyjímaje
count	integer	omezení počtu vrácených uživatelů

/stats/hashtags
GET Seznam používaných hashtagů

Bez použití následujících parametrů vrátí seznam všech hashtagů použitých v posledních 10 minutách společně s počtem jejich použití.

Výsledky jsou řazeny sestupně dle počtu použití v daném intervalu.

from	timestamp	od včetně
to	timestamp	do vyjímaje
count	integer	omezení počtu vrácených hashtagů

/stats/general
GET Obecné statistiky

Bez použití následujících parametrů vrátí obecné statistiky za posledních 10 minut.

from	timestamp	od včetně
to	timestamp	do vyjímaje
density	"40s"/"20m"/"1d"	hustota statistických dat

Implementace

V následujících sekcích jsou podrobněji popsány způsoby implementace jednotlivých částí systému. Způsob jeho nasazení je znázorněn na obrázku 4.1. Z důvodů zmíněných v sekci 4.1 byl však místo počítačového clusteru použit virtualizovaný systém na lokálním počítači.

Při vývoji systému i psaní tohoto textu byl používán verzovací systém GIT. Repozitář této práce je možné nalézt na serveru GitHub[36].

4.1 Analýza proudu dat

4.1.1 Výběr technologií


Framework Spark, který byl použit při implementaci analýzy proudu dat, nabízí API pro několik jazyků - Scala, Java, Python a R. API pro poslední dva zmiňované jazyky však neposkytují veškeré funkcionality Sparku, příkladem může být použití Twitter Streaming API jako zdroje dat[18]. Protože má právě Twitter sloužit jako zdroj dat pro tuto práci, v úvahu připadaly pouze jazyky Java a Scala.

Jak již bylo zmíněno v kapitole 1.2.1.1, výpočty lze distribuovat pro operace typu transformace, tedy například map, filter a reduce. Protože Scala je funkcionální jazyk obsahující podobné funkce již v základu, je v kontextu distribuovaných výpočtů ideální. I proto je samotný Spark naimplementovaný ve Scale[35]. Další výhodou je možnost použití existujících knihoven pro Javu. Především z těchto důvodů byla Scala použita i pro tuto práci.

4.1.1.1 Stanford NLP knihovna

Pro analýzu sentimentu byla namísto vlastní jednoduché implementace analýzy sentimentu použita Java knihovna Stanford NLP[32]. Jedná se o knihovnu obecně poskytující funkcionality pro zpracování a analýzu lidské řeči. Zahrnuje právě analyzátor pro určení sentimentu.

4. IMPLEMENTACE



Obrázek 4.1: Diagram nasazení implementovaného systému

Použitý model je nejdříve potřeba vytrénovat na vzorových datech. Bez manuálního přetrénování je algoritmus již vytrénován na datasetu složeného z necelých 10 tisíc vět z oblasti filmových hodnocení. Tato trénovací data je možné najít na stránce Stanford Dataset Treebank[37]. V rámci této práce nebude použitý model přetrénován přímo pro kontext sociální sítě Twitter, bylo by totiž potřeba manuálně ohodnotit řádově tisíce vět.

Výsledkem analýzy sentimentu pomocí Stanford NLP je hodnota v intervalu 0 až 4, kde 0 reprezentuje negativní a 4 pozitivní větu. Jednotlivé tweety tedy bylo nutné rozdělit na věty a každou z nich analyzovat zvlášť. Celkový sentiment tweetu byl pak určen na základě hodnocení jednotlivých vět a jejich délce.

4.1.2 Nasazení

Aby implementovaný systém zvládal analyzovat všechny publikované tweety, bylo by nutné jeho nasazení na počítačovém clusteru. K tomu je systém připravený a krom instalace potřebného software na jednotlivé stroje by nasazení nemělo vyžadovat další úpravy zdrojových kódů. Jak jsem ale popsal v sekci 2.2.3, ve volně dostupném API Twitter poskytuje pouze asi 1% publikovaných zpráv. Protože navíc počítačový cluster nemám k dispozici a jeho pronájem by byl velice nákladný, je program spouštěn na lokálním počítači ve virtualizovaném prostředí.

K dispozici má Spark 8GB RAM a 3 výpočetní jádra. Je ho spuštěn v tzv. lokálním režimu, ve kterém je na každém jádře spuštěn jeden výpočetní uzel. I kvůli omezeným zdrojům bylo v průběhu implementace nutné zvětšit délku intervalu, ve kterém Spark data zpracovává. Většina tohoto času je však overhead a s nárůstem objemu zpracovávaných dat není celková doba jejich analýzy výrazně navýšena.

4.1.3 Popis implementace

Celkový pohled na implementovaný systém zobrazuje diagram aktivit na obrázku 4.2. Po úspěšné inicializaci Sparku a přihlášení k Twitter Streaming API začnou probíhat dvě nezávislé větve programu. Samotné střežení dat z Twitteru vždy po dobu 40 vteřin řeší samotný Spark. Po uběhnutí daného intervalu jsou data poskytnuta jako RDD ke zpracování a ihned začíná další střežení dat.

Druhá větev má za úkol zpracování dat poskytnutých větví první. Ke zpracování další batche dochází kdykoli je dokončeno zpracování té předchozí a zároveň jsou k dispozici nová data. Program se tak může dostávat do zpoždění pokud data zpracovávají v daném intervalu nestíhá. Při zpracování dat z každého intervalu jsou nejprve vyfiltrovány anglické příspěvky reprezentující přání jejich autorů. Poté je vypočítán sentiment těchto přání a data o nich jsou uložena do databáze.

Několik zajímavých částí této implementace zobrazují následující zdrojové kódy. Před začátkem zpracování dat je krom připojení k Twitteru také potřeba provést základní nastavení Sparku. Nutné je především vytvořit kontexty, jak ukazuje zdrojový kód 4.1. Tyto kontexty budou později použity při operacích prováděných při zpracování dat. Vytvořen je také samotný stream.

4. IMPLEMENTACE

```
1 val conf = new SparkConf().setAppName("Twitter Wishes  
    Analysis")  
2  
3 val sc = new SparkContext(conf)  
4 val ssqlc = new SQLContext(sc)  
5 val ssc = new StreamingContext(sc, Seconds(40))  
6  
7 val stream = TwitterUtils.createStream(ssc, None)
```

Zdrojový kód 4.1: Vytvoření kontextů a streamu

Z vytvořeného streamu je potřeba vyfiltrovat pouze anglické příspěvky. K tomu je použita metoda *getLang()* dostupná v knihovně Twitter4j. Zdrojový kód 4.2 ukazuje také vyfiltrování pouze příspěvků reprezentujících přání jejich autorů.

```
1 // filter English tweets  
2 var tweetWishesStream = stream.filter( status => (  
    status.getLang() == "en"))  
3  
4 // filter wishes  
5 tweetWishesStream = tweetWishesStream  
6     .filter( status => (  
7         status.getText().contains("wish") ||  
8         status.getText().contains("hope") ||  
9         status.getText().contains("pray") ))
```

Zdrojový kód 4.2: Vyfiltrování anglických přání

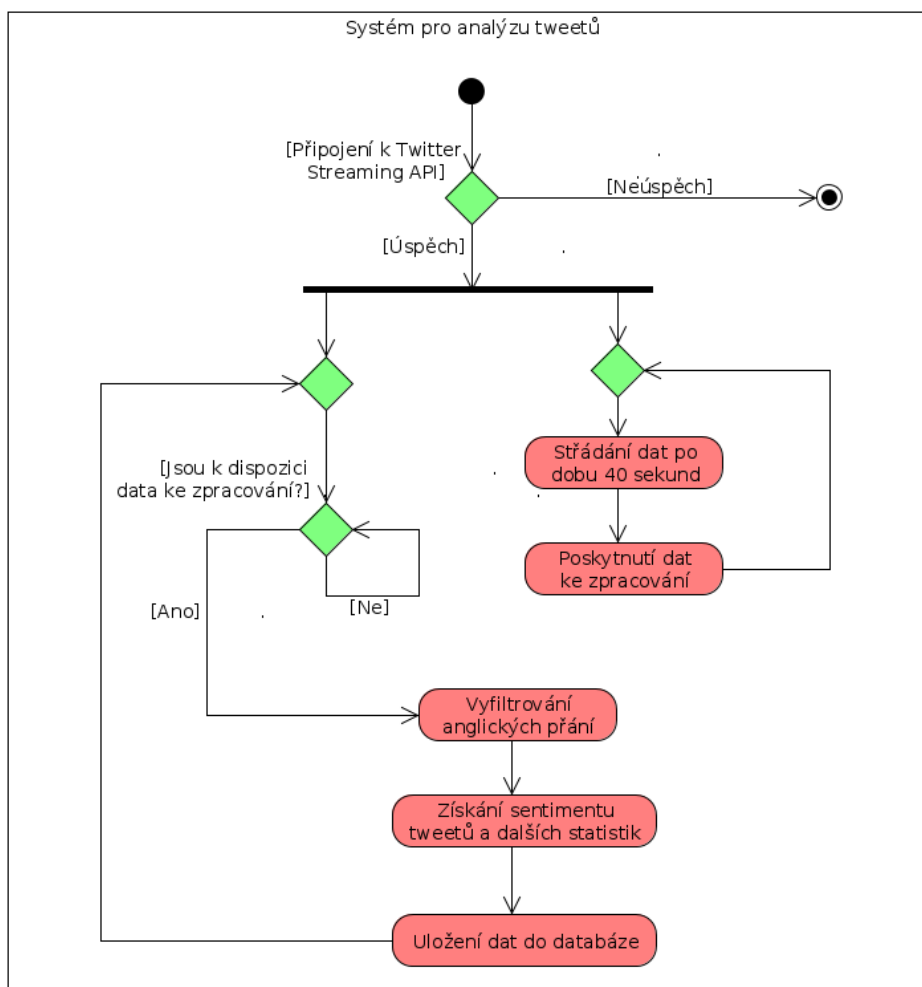
V další části již nastává samotná analýza vyfiltrovaných přání. Zdrojový kód 4.3 zobrazuje vytvoření DataFramu obsahujícího obecné statistiky v daném časovém intervalu a jejich uložení do databáze.

```
1 // write stats to DB  
2 val stats = ssqlc.createDataFrame(Seq((  
    currentDatetime, tweetCount,  
3    tweetCountEnglish, wishCount, average_sentiment)))  
4 .toDF("datetime",  
5     "tweets_total",  
6     "tweets_english",  
7     "wishes_total",  
8     "sentiment_average")  
9 stats.write.mode(SaveMode.Append).jdbc(DBUrl, "
```



```
stats_general_40s", prop)
```

Zdrojový kód 4.3: Ukládání statistik do databáze



Obrázek 4.2: Diagram aktivit systému pro analýzu tweetů

4.2 Databáze

4.2.1 Výběr technologií

Při výběru konkrétní databáze bylo nejdříve nutné rozhodnout, zda použít klasickou relační databázi nebo sáhnout po NoSQL databázi. NoSQL databáze,

někdy také označované jako Not Only SQL, zpravidla nejsou relační a nemají pevně dané schéma. Na druhou stranu tyto databáze nabízejí větší možnosti škálování, často jsou distribuované a umožňují pojmout výrazně větší objemy dat než databáze klasické[30]. NoSQL databáze se často využívají právě v projektech pracujících s Big Daty.

Jedněmi z nejrozšířenějších NoSQL databází jsou tzv. dokumentově orientované databáze. Příkladem takové databáze je MongoDB[38]. Data v nich jsou obvykle uložena ve formátu podobném JSONu, přičemž narozdíl od relačních databází často provádíme jejich denormalizaci. To umožňuje rychlejší načtení informací z databáze, aktualizace dat je obvykle ale naopak časově náročnější[39].

Z několika důvodů jsem však pro tuto práci zvolil klasickou relační databázi. Po vyfiltrování jednotlivých přání a jejich analýze nebudu pracovat s tak velkými objemy dat, které by relační databáze nebyla schopna pojmout. Tato data navíc mezi sebou mají jasné vztahy, které je možné zanást do schématu databáze a usnadnit si tak práci s nimi. Relační databáze jsou také využívány výrazně delší dobu a jsou vývojově vyspělejší.

Z volně dostupných databázových řešení jsou nejrozšířenější především MySQL a PostgreSQL. Protože tato práce neklade na databázi žádné specifické požadavky, výběr konkrétní databáze je možné založit pouze na obecných parametrech. Protože má MySQL velkou základnu uživatelů a díky autorovým zkušenostem s touto databází byla použita i v rámci této práce.

4.2.2 Nasazení databáze

Po výběru konkrétních databázových technologií byl potřeba zvolit vhodný způsob nasazení. Z důvodů popsaných v následující sekci nebyl k nasazení použit vlastní linuxový server, nicméně jedna z v poslední době stále rozšířenějších cloudových služeb.

4.2.2.1 Amazon RDS

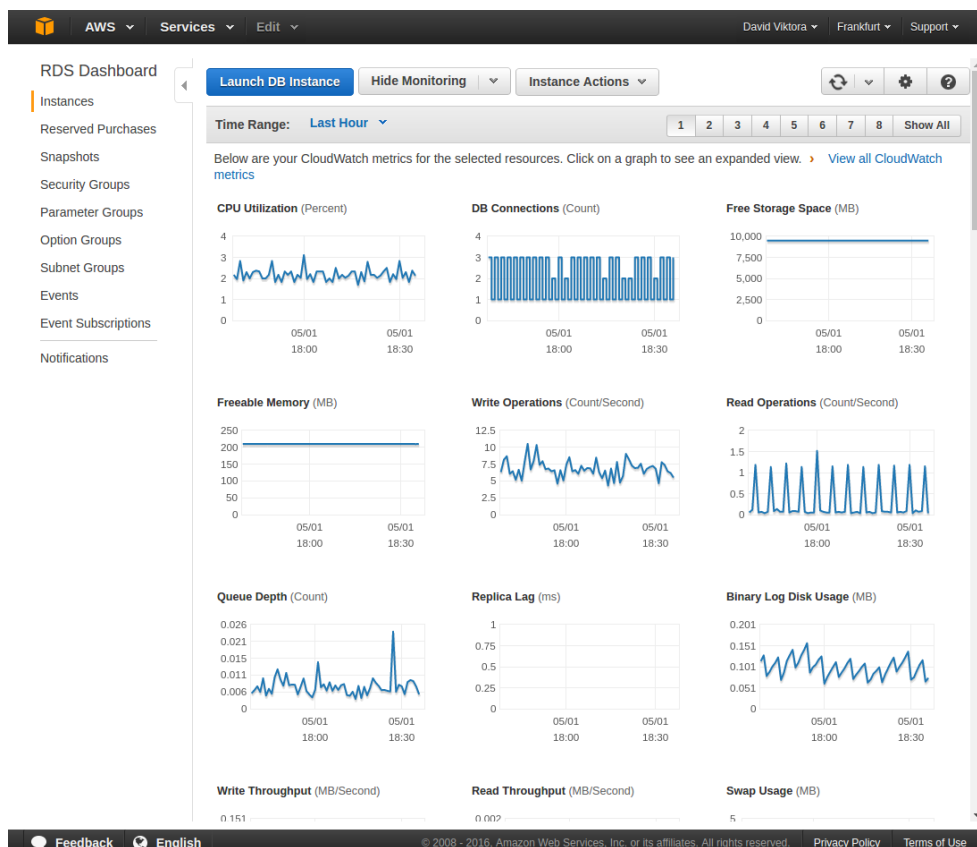
Konkrétně byla pro nasazení databáze využita služba Amazon AWS[40]. Amazon Web Services je kolekce cloudových služeb zahrnujících například cloudové úložiště, virtuální servery nebo právě databázové servery - tzv. Amazon RDS, neboli Relational Database Service.

Nabízené virtuální servery (Amazon EC2) jsou příkladem modelu IaaS - tedy Infrastructure as a Service. Uživatel se v případě IaaS nemusí starat o infrastrukturu, jsou mu ale poskytnuty přístupové údaje v tomto případě k linuxovému serveru a o veškeré další nastavení a provoz se stará sám. Amazon RDS je pak příkladem modelu PaaS, neboli Platform as a Service. V případě PaaS obecně odpadá i nutnost instalace softwaru a dalších administrátorských úkonů. Uživatel se stará pouze o konkrétní software provozovaný na dané platformě. U Amazon RDS tak není třeba manuálně instalovat databázi nebo

třeba nastavovat připojení systému k síti. Na druhou stranu to ani není možné a obecně model PaaS může přinášet i značná omezení.

Veškeré služby poskytované v rámci Amazon AWS je možno provozovat v celkem 12 regionech pokrývajících většinu světa. Česká Republika například spadá pod datacentrum umístěné ve Frankfurtu. Hlavní výhodou Amazon AWS a podobných služeb je výrazné usnadnění instalace i administrace a především jednoduchá škálovatelnost, obvykle je také zaručena určitá dostupnost služeb. Jak ukazuje obrázek 4.3, v případě Amazonu je výhodou také relativně podrobný monitoring. Nevýhodou oproti vlastnímu serveru může být především vyšší cena, v některých případech také zmiňované restrikce při nastavování služeb.

Ani v případě RDS není možné provést všechna nastavení, která by byla dostupná při použití vlastní instalace MySQL. Automaticky vytvořený uživatel totiž nemá neomezená práva a nemůže například měnit hodnoty globálních proměnných. Většinu jich lze nicméně nastavit pomocí tzv. profilů v administraci RDS. Příkladem takových nastavení je povolení MySQL Events, kterým se věnuji v následující sekci.



Obrázek 4.3: Monitoring databáze v Amazon RDS

4.2.3 Agregace dat v čase

Jedním z funkčních požadavků této práce je agregace statistických dat dle času. Agregovat data se vyplácí z několika důvodů. Tím hlavním je ale snížení náročnosti dotazů na tato data. Pokud například uživatel požaduje statistiky za poslední týden, nepotřebuje obvykle data za každých několik sekund, ale stačí mu již agregovaná data například po hodinách. Aniž by přišel o nějaké informace, jsou mu místo tisíců záznamů vráceny desítky. Agregace je možné dosáhnout například pomocí CRONu nebo přímo na úrovni databáze pomocí Event Scheduleru.

CRON je unixový systémový démon zajišťující provádění uživatelem definovaných příkazů v daném čase[41]. Stačilo by tedy napsat jednoduchý script, který by se připojil k databázi a provedl sloučení dat. Tento skript by pak byl pomocí CRONu pravidelně spouštěn. Protože byl pro nasazení databáze zvolen Amazon RDS, nemáme přístup k celému systému na kterém databáze běží, ale pouze k samotné databázi. CRON by tedy vyžadoval další UNIXový systém a není proto vhodným řešením.

Event Scheduler[42] poskytovaný přímo jako součást MySQL je naopak řešením ideálním. Jeho využití je oproti CRONu omezenější, nicméně pro námi požadovanou agregaci dat je jeho funkcionality postačující. Půjde navíc o čistší řešení, protože bude operace modifikující databázi řešena přímo na její úrovni.

Příkaz pro vytvoření eventu agregujícího data z tabulky *stats_general_40s* do tabulky *stats_general_20m* je k dispozici jako zdrojový kód 4.4:

```
1 CREATE EVENT 'stats_general_40s_to_20m'
2 ON SCHEDULE EVERY 20 MINUTE STARTS '2016-01-01
   00:01:00'
3 ON COMPLETION NOT PRESERVE ENABLE COMMENT
4 'Aggregate general stats 40s -> 20m'
5 DO BEGIN
6   INSERT INTO stats_general_20m (tweets_total,
7     tweets_english, wishes_total,
8     sentiment_average)
9   SELECT SUM(tweets_total), SUM(tweets_english),
10     SUM(wishes_total), AVG(sentiment_average)
11   FROM stats_general_40s
12   WHERE datetime > timestamp(utc_timestamp()
13     - interval 20 minute);
14 END;
```

Zdrojový kód 4.4: MySQL Event provádějící agregaci dat

Tento příkaz však provádí pouze slučování dat. Pro mazání dat starých bylo potřeba vytvořit další event popsany ve zdrojovém kódu 4.5. Ten zajišťuje mazání dat starších než 1 hodina v tabulce *stats_general_40s*:

```

1 CREATE EVENT 'stats_general_40s_clean'
2 ON SCHEDULE EVERY 10 MINUTE STARTS '2016-01-01
  00:00:00'
3 ON COMPLETION NOT PRESERVE ENABLE COMMENT 'Clean old
  data from stats_general_40s'
4 DO
5 DELETE FROM stats_general_40s
6 WHERE datetime < timestamp(utc_timestamp()
7   - interval 1 hour) */ ;;

```

Zdrojový kód 4.5: MySQL Event provádějící smazání starých dat

4.3 API webserver

4.3.1 Výběr technologií

Frameworky umožňující implementaci RESTového API existují pro víceméně všechny rozšířené programovací jazyky, některé z nich se však pro tyto účely hodí víc než jiné. Velice oblíbeným je například jazyk Python, který jsem především z důvodů jako jsou skvělá přehlednost kódu a rozsáhlá komunita zvolil i já. Z konkrétních frameworků jsem se poté rozhodoval především mezi minimalistickým Flaskem[43] a komplexnějším Djangoem[44].

Oba tyto frameworky mají kvalitní dokumentaci a stojí za nimi rozsáhlá komunita. Django je ale určený především pro tvorbu komplexních webových aplikací, kdežto Flask je označován za tzv. micro-framework. Poskytuje tedy jen základní funkcionality, které je možné rozšířit instalací dalších pluginů. Protože cílem je vytvoření pouze RESTového API, je Flask ideálním nástrojem bez pro tento projekt zbytečných funkcí.

Při implementaci bylo použito několik pluginů pro Flask:

- **flask-sqlalchemy** - SQLAlchemy je asi nejrozšířenějším ORM⁶ pro Python. Tento plugin integruje jeho funkcionality do frameworku Flask. Umožňuje tedy namapování jednotlivých tabulek databáze na třídy, se kterými je v programu možno jednoduše pracovat místo manuálního vytváření SQL dotazů.
- **flask-restless** - Tento plugin dále využívá SQLAlchemy a umožňuje především automatické vytváření API endpointů na základě definovaných databázových modelů.
- **flask-testing** - Flask-testing je plugin použitý pro testování API endpointů. Tomu se podrobněji věnuji v sekci 5.1.

⁶Objektově relační mapování umožňuje namapování tabulek v relační databázi na konkrétní třídy v programu

4.3.2 Ukázky implementace

Jednotlivé tabulky databáze jsou tedy pomocí ORM SQLAlchemy namapovány na třídy reprezentující objekty jako *user* nebo *tweetWish*. Příklad takového namapování tabulky *user* ukazuje zdrojový kód 4.6. Metodu *json_dump* bylo nutné naimplementovat pro všechny třídy. Ne všechny atributy jsou totiž implicitně serializovatelné a není je tak možné automaticky převádět na JSON.

```
1 class User(db.Model):
2     def __init__(self, id, username,
3         profile_picture_url):
4         self.id = id
5         self.username = username
6         self.profile_picture_url = profile_picture_url
7
8     __tablename__ = 'users'
9     id = db.Column(db.BigInteger, primary_key=True)
10    username = db.Column(db.String(140))
11    profile_picture_url = db.Column(db.Text)
12    wishes = relationship("TweetWish",
13        back_populates="user")
14    mentioned_in = relationship("TweetWish",
15        secondary=tweet_mentions_user,
16        lazy='dynamic',
17        back_populates="mentioned_users")
18
19    def json_dump(self):
20        return dict(id=str(self.id),
21            username=self.username,
22            profile_picture_url=self.
23                profile_picture_url)
```

Zdrojový kód 4.6: Ukázka použití ORM SQLAlchemy

Po namapování všech potřebných tabulek již můžeme v rámci programu pracovat s definovanými třídami. To platí i při vytváření konkrétních endpointů jak ukazuje zdrojový kód 4.7. Po definování konkrétní cesty, v tomto případě */user/<user_id>/*, již dochází jen ke kontrole počtu zadaných argumentů. Poté je jednoduše vrácen JSON obsahující údaje uživatele s daným ID nebo v případě neexistujícího uživatele HTTP status 404.

Obdobným způsobem jsou implementovány i další endpointy. Zajímavá je také nutnost přidání tzv. CORS hlaviček ke všem odpovědím. CORS neboli Cross Origin Resource Sharing je mechanismus umožňující webům získávání zdrojů z jiných domén. To je ale standardně z bezpečnostních důvodů zakázáno.

```

1 # return user with specified id
2 @app.route('/user/<user_id>', methods=['GET'])
3 def user(user_id):
4     if len(request.args) != 0:
5         raise ProcessingException(
6             description='Invalid argument provided',
7             code=400)
8
9     user = User.query\
10         .get_or_404(user_id)
11     return jsonify(user.json_dump())

```

Zdrojový kód 4.7: Ukázka implementace konkrétního API endpointu

4.3.3 Nasazení

Stejně jako v případě databáze, i pro webserver byly využity cloudové služby. Volba probíhala především mezi již probíraným Amazon AWS nebo službou zvanou Heroku[45]. Pro webserver by v případě Amazon AWS bylo nutno použít službu EC2, tedy virtuální server. EC2 je příkladem v kapitole 4.2.2.1 již popisovaného modelu IaaS. Heroku je však příkladem platformy (PaaS) umožňující mimo jiné i jednoduché spouštění aplikací psaných v Pythonu. Protože v případě Heroku odpadá nutnost administrace linuxového serveru a první nasazení aplikace je na něm otázkou několika minut, je pro námi požadovaný jednoduchý webserver skvělou volbou.

4.3.3.1 Heroku

Po vytvoření účtu na Heroku je potřeba stáhnout si tzv. Heroku Toolbelt. Jedná se o CLI⁷ nástroj sloužící právě ke správě a monitorování aplikací běžících v Heroku cloudu. Při vytváření nové aplikace si uživatel stejně jako v případě Amazon AWS nejdříve zvolí variantu služby na základě jeho hardwarových a jiných požadavků.

Konkrétní způsob nasazení aplikace se pak mírně liší pro každý z podporovaných jazyků, kterých je momentálně 8. V případě pythonu je nejdříve nutné vytvořit několik souborů:

- **requirements.txt** - seznam požadovaných knihoven pro Python vygenerovaný pomocí nástroje pip⁸, konkrétně příkazem *pip freeze*.
- **Procfile** - soubor určující jak a který soubor spustit po nahrání aplikace na Heroku

⁷Command line interface nástroje jsou nástroje pracující v prostředí příkazové řádky

⁸Balíčkovací systém umožňující instalaci a správu knihoven pro Python

- **runtime.txt** - určení verze pythonu použité pro spuštění aplikace

Nahrání aplikace na Heroku může probíhat několika způsoby, tím základním je ale použití GITu. Samotným vytvoření aplikace pomocí Heroku Toolbeltu dojde k přidání remote repozitáře. Do něj poté stačí nahrát změny pomocí příkazu *git push* a Heroku již v případě nalezení výše zmíněných souborů zařídí spuštění aplikace.

Protože k verzování této práce byl použit jeden společný repozitář namísto oddělených repozitářů pro každou komponentu, nastal samozřejmě problém s nahráním pouze adresáře obsahujícího soubory pro webserver. I toho je ale pomocí GITu možné dosáhnout. Jak ukazuje zdrojový kód 4.8 použit byl příkaz *git subtree*:

```
1 git push heroku_remote 'git subtree split --prefix  
  flask_api master':master --force
```

Zdrojový kód 4.8: Příkaz pro nahrání podadresáře na Heroku

4.4 Webová aplikace

Protože nejlepším způsobem otestování jakéhokoli software je jeho reálné použití, byla jako součást této práce vytvořena i webová aplikace využívající API popsané v předchozí kapitole. Ta poslouží také pro prezentaci výsledků prováděné analýzy. Protože web není součástí zadání této práce, budu se mu věnovat pouze z hlediska testování API v kapitole 5. Ukázky této aplikace jsou pak k nalezení v příloze B.

Webová aplikace je napsána pomocí jazyků HTML, CSS a JavaScript, použity byly i komponenty frameworku Bootstrap. K nasazení byl použit Amazon AWS, konkrétně služby Amazon S3 pro hostování dat a Amazon Route 53 pro nastavení vlastního doménového jména. Na webu jsou v reálném čase zobrazovány výsledky analýzy. Konkrétně jde například o nejnovější publikovaná přání, nepoužívanější hashtagy či graf zobrazující obecné statistiky.

Testování

Testování je důležitou součástí vývoje každého software a jinak tomu není ani v případě systému implementovaného v rámci této práce. Kromě manuálního testování prováděného během vývoje systému byly implementovány i automatické testy poskytovaného API. Pro prezentaci výsledků analýzy a zároveň pro otestování celého systému byl vytvořen také web zobrazující informace o analyzovaných přáních.

5.1 Test API endpointů

Při testování implementovaného API bylo použito rozšíření pro framework Flask zvané Flask-testing. To využívá knihovnu unittest, která je součástí standardní Python knihovny, a přidává několik funkcionalit zjednodušujících použití v rámci Flasku.

Po vytvoření třídy dědící od třídy *TestCase* je nejprve nutné vytvořit několik metod:

- **create_app** - jde o metodu volanou ještě před spuštěním prvního testu. Lze v něm například změnit konfigurační soubor a použít díky tomu testovací instanci databáze místo té produkční.
- **setUp** - tato metoda je spuštěna před každým jednotlivým testem. Jejím hlavním úkolem je naplnění databáze daty, která budou následně využita při testování.
- **tearDown** - metoda `tearDown` je naopak spouštěna na konci každého testu. V ní je obvykle databáze naopak přemazána.

Poté již stačí vytvořit jednotlivé testy. Za ty se automaticky považují všechny metody, jejichž název začíná slovem `test`. Ukázku testu zaměřeného na endpoint `/user/<user_id>` zobrazuje zdrojový kód 5.1. U všech endpointů je

5. TESTOVÁNÍ

testován především návratový kód, v některých případech i konkrétní odpověď webserveru.

```
1 def test_user_detail(self):
2     response = self.client.get('/user/123/',
3                                 query_string={})
4     assert response.status_code == 200
5     user = {'username': 'Jack', 'id': '123', '
        profile_picture_url': 'http://profile.picture.
        url'}
6     self.assertEqual(response.json, user)
```

Zdrojový kód 5.1: Test endpointu /user/<user_id>

5.2 Web prezentující výsledky analýzy

Vytvořenou webovou stránku je možné nalézt na adrese <http://tweetwishes.com>, pro její plnou funkcionalitu však musí být spuštěn i samotný systém pro analýzu tweetů. Na webu jsou totiž v reálném čase zobrazována nová přání, statistiky a další údaje. Obrázky webu jsou k dispozici v příloze B.

Web využívá velkou část implementovaných API endpointů. Ukázka jejich praktického použití je nejlepším způsobem otestování jejich správného návrhu a funkčnosti. Některé komponenty webu jsou zobrazeny na obrázcích XXXXXXXXXXXX.

Zhodnocení výsledků

Implementovaný systém dle požadavků provádí analýzu příspěvků publikovaných na Twitteru. Přestože původní plán rychlosti zpracování těchto příspěvků počítal s kratší dobou analýzy, její výsledky jsou dostupné na webu již během několika desítek sekund po publikování tweetů. Toto zpoždění je způsobeno slabým výpočetním výkonem a overheadem potřebným pro inicializaci Sparku a distribuci operací a dat.

Prováděná analýza vedla k zajímavým výsledkům. Jak ukazuje graf na obrázku 6.1, výrazně převažují negativní přání nad těmi pozitivními. Monitorováním nejpoužívanějších hashtagů bylo například možné sledovat vývoj amerických prezidentských voleb, velice aktivní byly také uživatelé z Filipín. I ti vyjadřovali svá přání týkající se voleb nového filipínského prezidenta. Kromě politických témat se v přáních často objevovala sportovní témata či příspěvky týkající se hudebních a filmových hvězd.


6.1 Využití systému

V současném stavu je implementovaný systém určen především pro pobavení a prezentaci použitých technologií. Nabízí se však několik možných využití, kterých by bylo možné dosáhnout jen drobnými úpravami tohoto systému.

Díky prováděné analýze sentimentu by mohlo jít obecně o úlohy zabývající se tzv. opinion miningem - díky analýze sentimentu příspěvků obsahujících dané výrazy či hashtagy by bylo možné například provádět předvolební průzkumy, hodnotit úspěšnost reklamní kampaně či určovat oblíbenost zvolených produktů a značek.

6.2 Možná budoucí vylepšení

Jedním z hlavních vylepšení systému by bylo bezesporu jeho nasazení na počítačový cluster. K tomu je celý systém připravený a díky dostupnému výkonu



Obrázek 6.1: Zde bude graf vývoje sentimentu

by stálo za zvážení zažádat o přístup k veškerým příspěvkům z Twitteru pomocí služby Gnip popsané v sekci 2.2.3.

Nabízí se i několik funkčních vylepšení celého systému. Jedním z nich je zobecnění tohoto systému, díky kterému by jeho využití nebylo omezeno na analýzů přání uživatelů, ale bylo by ho možné využívat například i pro výše zmíněné účely. Filtrované výrazy by byly zadány například do konfiguračního souboru. Až na přejmenování tabulek a proměnných by jiné výraznější zásahy do systému nebyly nutné.

Systém by také jistě bylo možné optimalizovat a snížit tak rychlost analýzy tweetů. Jednou z možností by bylo využití noSQL databáze a kompletní změna způsobu ukládání dat. Práce s relační SQL databází pomocí SparkSQL je totiž v některých směrech omezující a některé operace mohou dobu zpracování nežádoucím způsobem zvyšovat.

Zajímavé by bylo také rozšíření systému o další metody z oblasti text miningu a zpracování řeči, jejichž použití by v kontextu sociální sítě Twitter dávalo smysl.

Závěr

Cílem této bakalářské práce byla implementace systému pro analýzu proudu dat v reálném čase za použití frameworku Apache Spark. Analyzovanými daty pak měly být příspěvky ze sociální sítě Twitter, nad nimi měla být provedena některá z rozšířených metod pro analýzu textu. Výsledky analýzy měly být ukládány do databáze a zpřístupněny pomocí REST API.

V rámci kapitoly 1 jsem se zabýval hlavně technologiemi pro zpracování velkých objemů dat. Ve druhé kapitole jsem zmínil některé z nejpoužívanějších metod pro analýzu textu a zaměřil jsem se především na analýzu sentimentu, která je prováděna v rámci implementovaného systému. Také jsem v této kapitole seznámil čtenáře se sociální sítí Twitter a stanovil požadavky pro implementovaný systém. Na jejich základě jsem ve třetí kapitole navrhl konkrétní funkcionality systému, včetně struktury databáze nebo požadovaných API endpointů. V kapitole 4 jsem zvolil konkrétní technologie pro jednotlivé komponenty systému a popsal zajímavé části jejich implementace. Pro samotnou implementaci systému ve frameworku Apache Spark byl použit funkcionální jazyk Scala, k ukládání dat posloužila relační databáze MySQL. REST API pak bylo implementováno pomocí jazyka Python, konkrétně pomocí frameworku Flask. Systém byl také náležitě otestován jak popisují v kapitole 5.

Zadání této práce považuji za splněné. Požadovaný systém byl úspěšně naimplementován, konkrétní dosažené výsledky a možnosti využití systému jsou podrobně rozebrány v kapitole 6.

Literatura

- [1] WALL, Matthew. Big Data: Are you ready for blast-off? In: *BBC News* [online]. 2014 [cit. 2016-04-10]. Dostupné z: <http://www.bbc.com/news/business-26383058>
- [2] Internet Users. Internet Live Stats: *Internet Usage & Social Media Statistics* [online]. [cit. 2016-04-10]. Dostupné z: <http://www.internetlivestats.com/internet-users/>
- [3] Why Big Data And The Internet of Things Are A Perfect Match. In: *Datamation: IT Management, IT Salary, Cloud Computing, Open Source, Virtualization, Apps*. [online]. [cit. 2016-04-10]. Dostupné z: <http://www.datamation.com/applications/why-big-data-and-the-internet-of-things-are-a-perfect-match.html>
- [4] What is big data? *Webopedia: Online Tech Dictionary for IT Professionals* [online]. [cit. 2016-04-11]. Dostupné z: http://www.webopedia.com/TERM/B/big_data.html
- [5] TRÍSKA, Martin. *Customer Intelligence v kontextu Big Data*. Praha, 2013. Diplomová práce. České vysoké učení technické v Praze. Vedoucí práce Tomáš Bruckner.
- [6] Structured vs. Unstructured Data: The Rise of Data Anarchy. In: *Data Science Central* [online]. [cit. 2016-04-11]. Dostupné z: <http://www.datasciencecentral.com/profiles/blogs/structured-vs-unstructured-data-the-rise-of-data-anarchy>
- [7] MITTAL, Anshul a Arpit GOEL. Stock Prediction Using Twitter Sentiment Analysis. 2012. Dostupné také z: <http://cs229.stanford.edu/proj2011/GoelMittal-StockMarketPredictionUsingTwitterSentimentAnalysis.pdf>. Stanford University.

- [8] DEAN, Jeffrey a Sanjay GHEMAWAT. *MapReduce: simplified data processing on large clusters*. Google Inc., 2004.
- [9] What is MapReduce. *IBM* [online]. [cit. 2016-04-11]. Dostupné z: <http://www-01.ibm.com/software/data/infosphere/hadoop/mapreduce/>
- [10] MapReduce introduction. *Computer Science* [online]. [cit. 2016-04-16]. Dostupné z: <http://www.cs.uml.edu/~jlu1/doc/source/report/MapReduce.html>
- [11] The history of Hadoop: From 4 nodes to the future of data. In: *Gigaom: The industry leader in emerging technology research* [online]. [cit. 2016-04-17]. Dostupné z: <https://gigaom.com/2013/03/04/the-history-of-hadoop-from-4-nodes-to-the-future-of-data/>
- [12] Apache Spark: Lightning-Fast Cluster Computing [online]. [cit. 2016-04-17]. Dostupné z: <http://spark.apache.org/>
- [13] Welcome to Apache Hadoop! [online]. [cit. 2016-04-17]. Dostupné z: <http://hadoop.apache.org/>
- [14] Benchmarking Streaming Computation Engines at Yahoo!. *Yahoo Engineering* [online]. [cit. 2016-04-17]. Dostupné z: <https://yahooeng.tumblr.com/post/135321837876/benchmarking-streaming-computation-engines-at>
- [15] Fast Big Data: Apache Flink vs Apache Spark for Streaming Data. *Analytics, Data Mining, and Data Science* [online]. [cit. 2016-04-17]. Dostupné z: <http://www.kdnuggets.com/2015/11/fast-big-data-apache-flink-spark-streaming.html>
- [16] The 5-Minute Guide to Understanding the Significance of Apache Spark. *Big Data Hadoop Blog / MapR* [online]. [cit. 2016-04-17]. Dostupné z: <https://www.mapr.com/blog/5-minute-guide-understanding-significance-apache-spark>
- [17] *MLlib / Apache Spark* [online]. [cit. 2016-05-15]. Dostupné z: <http://spark.apache.org/mllib/>
- [18] Spark Streaming Programming Guide. *Overview - Spark 1.6.1 Documentation* [online]. [cit. 2016-04-17]. Dostupné z: <http://spark.apache.org/docs/latest/streaming-programming-guide.html>
- [19] What is/are the main difference(s) between Flink and Storm? *Stack Overflow* [online]. [cit. 2016-04-17]. Dostupné z: <http://stackoverflow.com/questions/30699119/what-is-are-the-main-differences-between-flink-and-storm>

-
- [20] The Apache Software Foundation Announces Apache Spark as a Top-Level Project. *The Apache Software Foundation* [online]. [cit. 2016-04-17]. Dostupné z: https://blogs.apache.org/foundation/entry/the_apache_software_foundation_announces50
- [21] What is the difference between Apache Spark and Apache Hadoop (Map-Reduce) ? *Quora* [online]. [cit. 2016-04-17]. Dostupné z: <https://www.quora.com/What-is-the-difference-between-Apache-Spark-and-Apache-Hadoop-Map-Reduce>
- [22] Getting started with Apache Spark GraphX – Part 1. *PhData* [online]. [cit. 2016-04-17]. Dostupné z: <https://phdata.io/getting-started-with-apache-spark-graphx-part-1/>
- [23] By The Numbers: 170+ Amazing Twitter Statistics. *DMR* [online]. [cit. 2016-04-19]. Dostupné z: <http://expandedramblings.com/index.php/march-2013-by-the-numbers-a-few-amazing-twitter-stats/>
- [24] Twitter Usage Statistics. *Internet Live Stats: Internet Usage & Social Media Statistics* [online]. [cit. 2016-04-19]. Dostupné z: <http://www.internetlivestats.com/twitter-statistics/>
- [25] Twitter Basics: Why 140-Characters, And How to Write More. *Social Times: Covering the world of social media* [online]. [cit. 2016-04-19]. Dostupné z: <http://www.adweek.com/socialtimes/twitter-basics-why-140-characters-and-how-to-write-more/442608>
- [26] GET statuses/sample. *Twitter Developers* [online]. [cit. 2016-04-20]. Dostupné z: <https://dev.twitter.com/streaming/reference/get/statuses/sample>
- [27] The Streaming APIs Overview. *Twitter Developers* [online]. [cit. 2016-04-20]. Dostupné z: <https://dev.twitter.com/streaming/overview>
- [28] Twitter4J - A Java library for the Twitter API [online]. [cit. 2016-04-20]. Dostupné z: <http://twitter4j.org/en/index.html>
- [29] Gnip: Unleash the Power of Social Media [online]. [cit. 2016-04-20]. Dostupné z: <https://gnip.com/>
- [30] NOSQL Databases [online]. [cit. 2016-04-26]. Dostupné z: <http://nosql-database.org/>
- [31] GANESAN, Kavita, ChengXiang ZHAI a Jiawei HAN. *Opino-sis: A Graph-Based Approach to Abstractive Summarization of Highly Redundant Opinions* [online]. [cit. 2016-05-15]. Dostupné z:

- http://dl.acm.org/ft_gateway.cfm?id=1873820&type=pdf&coll=DL&dl=GUIDE&CFID=84550979&CFTOKEN=79883382. University of Illinois at Urbana-Champaign.
- [32] *Software - The Stanford Natural Language Processing Group* [online]. [cit. 2016-05-15]. Dostupné z: <http://nlp.stanford.edu/software/>
- [33] FIELDING, Roy Thomas. *Representational State Transfer (REST)* [online]. 2000 [cit. 2016-05-15]. Dostupné z: https://www.ics.uci.edu/~fielding/pubs/dissertation/rest_arch_style.htm. University of California, Irvine.
- [34] *Introducing JSON* [online]. [cit. 2016-05-15]. Dostupné z: <http://www.json.org/>
- [35] Apache Spark: A Delight for Developers. In: *The modern platform for data management and analytics*. [online]. [cit. 2016-05-15]. Dostupné z: <http://blog.cloudera.com/blog/2014/03/apache-spark-a-delight-for-developers/>
- [36] *Fanarim/bt-spark: Twitter stream analysis in Apache Spark - bachelor thesis* [online]. [cit. 2016-05-15]. Dostupné z: <https://github.com/Fanarim/bt-spark>
- [37] Recursive Deep Models for Semantic Compositionality Over a Sentiment Treebank. *The Stanford Natural Language Processing Group* [online]. [cit. 2016-05-15]. Dostupné z: <http://nlp.stanford.edu/sentiment/treebank.html>
- [38] *MongoDB for GIANT Ideas* | MongoDB [online]. [cit. 2016-05-15]. Dostupné z: <https://www.mongodb.com/>
- [39] What makes NoSQL type databases fast and scalable compared to relational SQL based databases? In: *Quora* [online]. [cit. 2016-05-15]. Dostupné z: <https://www.quora.com/What-makes-NoSQL-type-databases-fast-and-scalable-compared-to-relational-SQL-based-databases>
- [40] *Amazon Web Services (AWS) - Cloud Computing Services* [online]. [cit. 2016-05-15]. Dostupné z: <https://aws.amazon.com/>
- [41] CronHowto - Community Help Wiki. *Official Ubuntu Documentation* [online]. [cit. 2016-05-15]. Dostupné z: <https://help.ubuntu.com/community/CronHowto>
- [42] MySQL :: MySQL 5.7 Reference Manual :: 21.4 Using the Event Scheduler. *MySQL :: Developer Zone* [online]. [cit. 2016-05-15]. Dostupné z: <https://dev.mysql.com/doc/refman/5.7/en/event-scheduler.html>

- [43] *Welcome / Flask (A Python Microframework)* [online]. [cit. 2016-05-15]. Dostupné z: <http://flask.pocoo.org/>
- [44] *The Web framework for perfectionists with deadlines / Django* [online]. [cit. 2016-05-15]. Dostupné z: <https://www.djangoproject.com/>
- [45] Cloud Application Platform | Heroku [online]. [cit. 2016-05-15]. Dostupné z: <https://www.heroku.com/home>

Definice API endpointů

**/wish/
GET**

Seznam přání

Bez použití následujících parametrů vrátí všechna přání za posledních 10 minut. Při použití *count* jsou ignorovány parametry *from* a *to*.

from	timestamp	od včetně
to	timestamp	do vyjímaje
count	integer	omezení počtu vrácených přání

Příklad odpovědi:

```
1  {
2    "wishes": [
3      {
4        "author": {
5          "id": 2745306105,
6          "profile_picture_url": "http://pbs.twimg.com
7            /..",
8          "username": "moley Jem"
9        },
10       "created_at": "2016-04-25 20:13:11",
11       "id": 724692755319021569,
12       "is_retweet": false,
13       "retweet_tweet_id": 724692755319021569,
14       "sentiment": 1.0,
15       "tweet_text": "I just wish...that's all"
16     },
17     ...
18   ]
19 }
```

A. DEFINICE API ENDPOINTŮ

`/wish/{wish_id}`

GET

Konkrétní přání

Vrací stejné údaje jako `/wish/`, ale pouze pro konkrétní přání s daným `wish_id`.

Příklad odpovědi:

```
1 {
2   "author": {
3     "id": 19748673,
4     "profile_picture_url": "http://pbs.twimg.com/pro
      ...",
5     "username": "DJ Romeo Reyes"
6   },
7   "created_at": "2016-04-25 20:12:44",
8   "id": 724692642039111680,
9   "is_retweet": false,
10  "retweet_tweet_id": 724692642039111680,
11  "sentiment": 2.0,
12  "tweet_text": "I hope the Blazers take the series
      to..."
13 }
```

`/wish/{wish_id}/mentions`

GET

Uživatelé zmíněný v přání

Vrací seznam uživatelů zmíněných v přání s daným `wish_id`.

Příklad odpovědi:

```
1 {
2   "mentioned_users": [
3     {
4       "id": 389507955,
5       "profile_picture_url": "",
6       "username": "EJ Gomez"
7     },
8     ...
9   ]
10 }
```

/wish/{wish_id}/hashtags

GET

Hashtagy použité v přání

Vrací seznam hashtagů použitých v přání s daným *wish_id*.

Příklad odpovědi:

```
1 {
2   "hashtags": [
3     {
4       "hashtag": "summer"
5     },
6     ...
7   ]
8 }
```

/user/

GET

Seznam uživatelů

Vrací seznam všech uživatelů, tedy autorů přání nebo uživatelů zmíněných v některém z nich.

Příklad odpovědi:

```
1 {
2   "users": [
3     {
4       "id": 12,
5       "profile_picture_url": "",
6       "username": "Jack"
7     },
8     ...
9   ]
10 }
```

/user/{user_id}

GET

Konkrétní uživatel

Vrací údaje o konkrétním uživateli s daným *user_id*.

Příklad odpovědi:

```
1 {
2   "id": 12,
3   "profile_picture_url": "",
```

A. DEFINICE API ENDPOINTŮ

```
4  "username": "Jack"
5  }
```

/user/{user_id}/wishes

GET

Přání daného uživatele

Vrací seznam přání uživatele s daným *user_id*.

Příklad odpovědi: viz */wish/{wish_id}*

/user/{user_id}/mentioned_in

GET

Zmínění daného uživatele

Vrací seznam přání, ve kterých byl uživatel s daným *user_id* zmíněn.

Příklad odpovědi: viz */wish/{wish_id}*

/hashtag/{hashtag}/wishes

GET

Přání obsahující daný hashtag

Vrací seznam přání, ve kterých byl použit daný *hashtag*.

Příklad odpovědi: viz */wish/*

/stats/mentions

GET

Seznam zmiňovaných uživatelů

Bez použití následujících parametrů vrátí seznam všech zmíněných uživatelů v posledních 10 minutách společně s počtem jejich zmínění.

Výsledky jsou řazeny sestupně dle počtu zmínění v daném intervalu.

from timestamp od včetně

to timestamp do vyjímaje

count integer omezení počtu vrácených uživatelů

Příklad odpovědi:

```
1  {
2    "popular_users": [
3      {
4        "mention_count": 5,
5        "user": {
6          "id": 42562446,
7          "profile_picture_url": "",
8          "username": "Stephen Curry"
9        }
10   }
```

```

10     },
11     ...
12 ]
13 }
```

/stats/hashtags

GET

Seznam používaných hashtagů

Bez použití následujících parametrů vrátí seznam všech hashtagů použitých v posledních 10 minutách společně s počtem jejich použití.

Výsledky jsou řazeny sestupně dle počtu použití v daném intervalu.

from timestamp od včetně

to timestamp do vyjímaje

count integer omezení počtu vrácených hashtagů

Příklad odpovědi:

```

1 {
2   "popular_hashtags": [
3     {
4       "count": 3,
5       "hashtag": "dubnation"
6     },
7     ...
8   ]
9 }
```

/stats/general

GET

Obecné statistiky

Bez použití následujících parametrů vrátí obecné statistiky za posledních 10 minut.

from timestamp od včetně

to timestamp do vyjímaje

density "40s"/"20m"/"1d" hustota statistických dat

Příklad odpovědi:

```

1 {
2   "stats": [
3     {
4       "datetime": "2016-04-25 20:43:29",
5       "sentiment_average": 2.1570285426245794,
6       "tweets_english": 644,
7       "tweets_total": 1591,
```

A. DEFINE API ENDPOINT

```
8     "wishes_total": 9
9     },
10    ...
11   ]
12 }
```

Ukázky webové aplikace

Seznam použitých zkratek

API	Application programming interface
AWS	Amazon Web Services
CLI	Command-line interface
CORS	Cross-origin resource sharing
CRUD	Create, Read, Update, Delete
CSS	Cascading Style Sheets
DF	Data frame
DStream	Discretized Stream
HDFS	Hadoop Distributed File System
HTML	HyperText Markup Language
HTTP	Hypertext Transfer Protocol
JDBC	Java Database Connectivity
JSON	JavaScript Object Notation
ODBC	Open Database Connectivity
ORM	Object-relational mapping
RDD	Resilient Distributed Dataset
RDS	Amazon Relational Database Service
REST	Representational State Transfer
RT	Retweet

C. SEZNAM POUŽITÝCH ZKRATEK

SQL Structured Query Language

URI Uniform Resource Identifier

YARN Yet Another Resource Negotiator

Obsah přiloženého CD

flask_api	Zdrojové kódy pro webserver poskytující REST API
├─ run_howto.txt	Instrukce pro spuštění webserveru
stream_analysis	Zdrojové kódy pro systém na analýzu tweetů
├─ Tweets_stream_analysis-assembly-0.1.jar	Jar pro spuštění
├─ installation.txt	Instrukce pro přípravu systému
├─ run_howto.txt	Instrukce pro spuštění
thesis	Zdrojové kódy tohoto textu
web	zdrojové kódy webové aplikace
db_model.png	Obrázek struktury databáze
db_structure.sql	SQL kód pro inicializaci databáze
db_cred.txt	Soubor obsahující přístupové údaje k databázi